

Comparaison

d'algorithmes de classification supervisée

Antoine Cornuéjols

AgroParisTech – INRAE Paris-Saclay

antoine.cornuejols@agroparistech.fr

Which metrics?

- Consistency (get it right sometimes vs every time)
- Robustness (work even when conditions are imperfect)
- Calibration (know when you succeeded/failed)
- Operational safety (avoid catastrophic errors)

But **creativity**, among other dimensions of intelligence, is the epitome of an unverifiable task.

- We don't even know clearly **how to test AI creativity**. We don't understand human creativity well enough from a cognitive science and neuroscience perspective to be able to have clear tests for it.

The AI creativity paradox

Dwarkesh Patel:

[LLMs] have basically the entire corpus of human knowledge memorized and they haven't been able to make a single new connection that has led to a discovery.

- Understanding this requires combining the variation/evaluation paradigm
 - ([J.P. Guilford](#), [Donald T. Campbell](#), [Margaret Boden](#), [Rich Sutton](#), ...)
- and the structure mapping / analogical reasoning paradigm
 - ([Arthur Koestler](#), [Dedre Gentner](#), [Douglas Hofstadter](#), [François Chollet](#), ...).

Some hypotheses about AI creativity

1. **Representation quality** is absolutely fundamental to cognition. Think about deep learning — what a big leap that was in the quality of representations behind perception. So I do think AI has more or less caught up in representation quality when it comes to *perception*, but **it has not caught up when it comes to representations that we use as humans for *creativity and reasoning*.**
 - **François Chollet** in particular has talked about the fact that human representations that underpin our creativity seem to exhibit a kind of extreme compositionality, where everything is built up from a few "atoms of meaning". Many seeming limitations of human working memory and information processing actually turn out to be strengths, because they force us to come up with these extremely efficient representations.
 - Because LLMs are much better than humans in certain dimensions — like memorizing and retrieving stored patterns that might enable creativity — we're not able to elicit these important real limitations in studies that try to compare human and LLM creativity.

-
- Furthermore, we humans can do something beautiful when we're creatively thinking about a problem: we improve our representations related to the problem in real time — at inference time, if you will. That enables us to sleep on it, improve our representations, and come back the next day much more efficient at solving that particular problem. I'm sure we've all experienced this. But it is something that today's AI systems are not able to do.
 - I assumed naively that the continual learning people would be all over this, but when I started looking into that literature, it appears to me that that's not the case. Continual learning is mostly focused on preventing catastrophic forgetting, as opposed to improving things over time. And furthermore, it is more focused on facts, skills, etc., as opposed to the quality of the underlying representations.

-
- How we evaluate research itself must change
 - *Position: There are futures that benchmark-driven AI cannot see.*
Sobhan Lotfi, Ava Iranmanesh et al. ICML 2026 Oral.

-

-

- Benchmark-based evaluation is *effective* but greatly *narrows* the field.

-



-
- What **benchmarks** give us is efficiency. We don't have to spend years peer-reviewing papers — if it beats the state of the art, we know it's probably a good paper. But unfortunately, it has narrowed the collective vision of the community. **We're searching under streetlights** — we are searching the kinds of things that are easy to search in a benchmark-driven evaluation regime. **We need to move beyond that.** That means **evaluating how good a paper is will become much more costly**. Sadly, that is a cost that we will have to pay. Right now the community is trying to rush in the opposite direction.

Plan

1. Introduction

2. Comparaison sur les **mêmes jeux de données**

1. T-test couplé
2. Test de McNemar
3. 5 x 2 cv tests couplés

3. Comparaison sur des **jeux de données différents**

1. Test de rang signé de Wilcoxon

4. Conclusions


Un algorithme et plusieurs tests (e.g. 10-CV)

- Soient $\hat{\epsilon}_1, \hat{\epsilon}_2, \dots, \hat{\epsilon}_k$ les k taux d'erreur mesurés
- Alors on a la **moyenne** et la **variance** :

$$\mu = \frac{1}{k} \sum_{i=1}^k \hat{\epsilon}_i \quad \sigma^2 = \frac{1}{k-1} \sum_{i=1}^k (\hat{\epsilon}_i - \mu)^2$$

- En considérant que les k taux d'erreur sont des tirages i.i.d. du taux d'erreur en généralisation, alors la variable $\mathcal{T}_t$ suit une **distribution t** à $k-1$ degrés de liberté.

$$\tau_t = \frac{\sqrt{k}(\mu - \epsilon_0)}{\sigma}$$



Un algorithme et plusieurs tests (e.g. 10-CV) (2)


- Pour l'hypothèse $\mu = \epsilon_0$ et le niveau de confiance α , on peut calculer l'erreur observable maximale avec une probabilité $1 - \alpha$ (ici avec une hypothèse à deux côtés (« two-sided »))
- Si** $\tau_t \in [t_{\alpha/2}, t_{\alpha/2}]$
- Alors** l'hypothèse que μ (taux d'erreur apparent) est **significativement différent** de ϵ_0 peut être **rejetée**

$$\tau_t = \frac{\sqrt{k}(\mu - \epsilon_0)}{\sigma}$$

Valeurs usuelles pour le t-test à deux côtés

α	k				
	2	5	10	20	30
0.05	12.706	2.776	2.262	2.093	2.045
0.10	6.314	2.132	1.833	1.729	1.699

$t_{\alpha/2}$



Comparaison de **2** algorithmes
sur **un** même jeu de données

Comparaison d'algorithmes

- Principe général
 - Caractériser la **distribution de probabilité** sur les différences possibles de performances sous **hypothèse nulle** H_0 : pas de différence en fait entre les algorithmes
 - **Décider** qu'il y a une différence si la **probabilité des différences observées est suffisamment petite sous H_0** .
(donc, c'est peu probable sous H_0)

Le two-match-sample t-test

- Teste si la **différence** entre deux échantillons (de performances) est **significative**
 - Fonction de la **différence de moyennes**
 - Fonction de la **différence de variance**
- On fait souvent l'hypothèse suivante sur la **distribution de la différence des moyennes**
 - Tend vers une **loi normale**

2 algorithmes : t-test en validation croisée

- Soient deux algorithmes A et B avec les erreurs respectives :
 $\epsilon_1^A, \epsilon_2^A, \dots, \epsilon_k^A$ et $\epsilon_1^B, \epsilon_2^B, \dots, \epsilon_k^B$

- On calcule les différences pour chaque paire de résultats

$$\Delta_i = \epsilon_i^A - \epsilon_i^B$$

- Si les deux algorithmes sont de performances équivalentes, la moyenne des différences devrait être proche de 0.
- On réalise donc un t-test sur les valeurs $\Delta_1, \Delta_2, \dots, \Delta_k$ avec l'hypothèse H_0 : A et B sont de même performance

2 algorithmes : t-test en validation croisée (2)

- Soient deux algorithmes A et B
- Avec les différences de performances $\Delta_i = \epsilon_i^A - \epsilon_i^B$
- On calcule la moyenne μ et la variance σ^2 des Δ_i

Et **si** $\tau_t = \left| \frac{\sqrt{k} \mu}{\sigma} \right| < t_{\alpha/2, k-1}$ au niveau de signification α

Alors H_0 (même performance) ne peut être rejetée

- Rq : Les Δ_i ne sont pas i.i.d. d'où la suggestion de 5x2 validation croisée de Tom Dietterich (1998)

Illustration : Comparaison de performances sur 10-CV

<i>Fold</i>	<i>Naive Bayes</i>	<i>Decision tree</i>	<i>Nearest neighbour</i>
1	0.6809	0.7524	0.7164
2	0.7017	0.8964	0.8883
3	0.7012	0.6803	0.8410
4	0.6913	0.9102	0.6825
5	0.6333	0.7758	0.7599
6	0.6415	0.8154	0.8479
7	0.7216	0.6224	0.7012
8	0.7214	0.7585	0.4959
9	0.6578	0.9380	0.9279
10	0.7865	0.7524	0.7455
avg	0.6937	0.7902	0.7606
stdev	0.0448	0.1014	0.1248

From [Peter Flach (2012) Machine Learning. *The art and science of algorithms that make sense of data*. Cambridge University Press]

Illustration : Comparaison de performances sur 10-CV

<i>Fold</i>	<i>Naive Bayes</i>	<i>Decision tree</i>	<i>Nearest neighbour</i>
1	0.6809	0.7524	0.7164
2	0.7017	0.8964	0.8883
3	0.7012	0.6803	0.8410
4	0.6913	0.9102	0.6825
5	0.6333	0.7758	0.7599
6	0.6415	0.8154	0.8479
7	0.7216	0.6224	0.7012
8	0.7214	0.7585	0.4959
9	0.6578	0.9380	0.9279
10	0.7865	0.7524	0.7455
avg	0.6937	0.7902	0.7606
stdev	0.0448	0.1014	0.1248

<i>Fold</i>	<i>NB-DT</i>	<i>NB-NN</i>	<i>DT-NN</i>
1	-0.0715	-0.0355	0.0361
2	-0.1947	-0.1866	0.0081
3	0.0209	-0.1398	-0.1607
4	-0.2189	0.0088	0.2277
5	-0.1424	-0.1265	0.0159
6	-0.1739	-0.2065	-0.0325
7	0.0992	0.0204	-0.0788
8	-0.0371	0.2255	0.2626
9	-0.2802	-0.2700	0.0102
10	0.0341	0.0410	0.0069
avg	-0.0965	-0.0669	0.0295
stdev	0.1246	0.1473	0.1278
<i>p-value</i>	0.0369	0.1848	0.4833

P-value = probabilité d'un résultat au moins aussi « extrême » que le résultat observé sous hypothèse H_0 .

La p-valeur dans la dernière ligne est calculée en utilisant la *t*-distribution avec $k - 1 = 9$ degrés de liberté. Et seule la différence entre Naïve Bayes et les Arbres de Décision est jugée significative au niveau $\alpha = 0.05$. ($0.0369 < 0.05$)

From [Peter Flach (2012) Machine Learning. *The art and science of algorithms that make sense of data*. Cambridge University Press]


Le test de McNemar

- Au lieu de regarder la différence de taux d'erreur, on peut **comparer les taux de classification correcte et incorrecte**
- Si les performances de A et B sont équivalentes alors on devrait avoir : $e_{01} = e_{10}$
- La variable $|e_{01} - e_{10}|$ suit une distribution gaussienne
- Le **test de McNemar** considère la variable qui suit une loi du chi2
- H_0 ne peut être rejetée au niveau α si

Algorithm B	Algorithm A	
	Correct	Incorrect
Correct	e_{00}	e_{01}
Incorrect	e_{10}	e_{11}

$$\tau_{\chi^2} = \frac{(|e_{01} - e_{10}| - 1)^2}{e_{01} + e_{10}}$$

$$\tau_{\chi^2} = \frac{(|e_{01} - e_{10}| - 1)^2}{e_{01} + e_{10}} < \chi_{\alpha}^2$$



Comparaison de **2** algorithmes
sur **plusieurs** jeux de données

Remarque fondamentale

- La **performance** des algorithmes **dépend de** leur adéquation au jeu de données traité
- **On ne peut plus** faire l'hypothèse que les taux d'erreur sur les différents jeux de données sont distribués selon une **loi normale**

→ Il faut recourir à des tests **non paramétriques**

Le test de rang signé de Wilcoxon

On calcule la **somme des rangs** :

$$W_{s1} = \sum_{i=1}^n I(d_i > 0) \text{rank}(d_i) \quad \text{et} \quad W_{s2} = \sum_{i=1}^n I(d_i < 0) \text{rank}(d_i)$$

$$\text{où} \quad d_i = \text{Perf}_{\text{moy}}(h_2) - \text{Perf}_{\text{moy}}(h_1)$$

Puis :

$$T_{\text{wilcox}} = \min(W_{s1}, W_{s2})$$

La distribution de T_{wilcox} peut être approchée par une loi normale **quand $n \geq 25$** (sinon regarder dans une table)

– On calcule la statistique z

$$z_{\text{wilcox}} = \frac{T_{\text{wilcox}} - \mu_{T_{\text{wilcox}}}}{\sigma_{T_{\text{wilcox}}}}$$

– Avec :

$$\mu_{\text{wilcox}} = \frac{n(n+1)}{4}$$

et

$$\sigma_{T_{\text{wilcox}}} = \sqrt{\frac{n(n+1)(2n+1)}{24}}$$

Le test de rang signé de Wilcoxon

Application

Table 6.4. Classifiers NB and SVM data ran on 10 realistic domains and used in the Wilcoxon test example

Domain no.	NB accuracy	SVM accuracy	NB-SVM	NB-SVM	Ranks (NB-SVM)	± Ranks (NB-SVM)
1	0.9643	0.9944	-0.0301	0.0301	3	-3
2	0.7342	0.8134	-0.0792	0.0792	6	-6
3	0.7230	0.9151	-0.1921	0.1921	8	-8
4	0.7170	0.6616	+0.0554	0.0554	5	+5
5	0.7167	0.7167	0	0	Remove	Remove
6	0.7436	0.7708	-0.0272	0.0272	2	-2
7	0.7063	0.6221	+0.0842	0.0842	7	+7
8	0.8321	0.8063	+0.0258	0.0258	1	+1
9	0.9822	0.9358	+0.0464	0.0464	4	+4
10	0.6962	0.9990	-0.3028	0.3028	9	-9

Avec $n-1 = 9$ degrés de liberté

Il faut $T_{wilcox} < 8$ (one-sided)

ou $T_{wilcox} < 5$ (two-sided)


(d'après la table pour $p=0.05$)

Donc on ne peut pas rejeter l'hypothèse nulle d'égalité
entre les algorithmes à $p = 0.05$

$$\left\{ \begin{array}{l} W_{s1} = 28 = 3 + 6 + 8 + 2 + 9 \\ W_{s2} = 17 = 5 + 7 + 1 + 4 \end{array} \right.$$

$$T_{wilcox} = \min(W_{s1}, W_{s2}) = 17$$

From [Japowicz & Shah (2011) "Evaluating Learning Algorithms. A classification perspective", p.235]



Comparison de **N** algorithmes
sur **plusieurs** jeux de données

-
- Situation du **test d'hypothèses multiples**
 - Problème : un algorithme **peut sembler meilleur** par le hasard des tests (cf. lien entre risque empirique et risque réel)
 - **Post hoc tests**
 - **Une fois que** des tests statistiques ont montré une différence entre algorithmes, les **tests post hoc** cherchent quels algorithmes sont effectivement différents
 - Le **test de Nemenyi** est un test post-hoc très employé

Le test de Nemenyi

- Calcule une ***q* statistique** sur la *différence entre les rangs moyens*

- Let R_{ij} be the rank of classifier f_j on dataset S_i .
- We compute the mean rank of classifier f_j on all datasets:

$$\bar{R}_{.j} = \frac{1}{n} \sum_{i=1}^n R_{ij}.$$

- For any two classifiers f_{j1} and f_{j2} , we compute the q statistic as

$$q = \frac{\bar{R}_{.j1} - \bar{R}_{.j2}}{\sqrt{\frac{k(k+1)}{6n}}}.$$

- The null hypothesis is rejected after a comparison of the obtained q value with the q value for the desired significance table for critical q_α values, where α refers to the significance level.²⁵ Reject the null hypothesis if the obtained q value exceeds q_α .

Illustration

Exemple pour **trois** algorithmes f_A , f_B et f_C

Table 6.6. *Sample accuracy results for classifiers f_A , f_B , and f_C on 10 domains*

Domain	Classifier f_A	Classifier f_B	Classifier f_C
1	85.83	75.86	84.19
2	85.91	73.18	85.90
3	86.12	69.08	83.83
4	85.82	74.05	85.11
5	86.28	74.71	86.38
6	86.42	65.90	81.20
7	85.91	76.25	86.38
8	86.10	75.10	86.75
9	85.95	70.50	88.03
10	86.12	73.95	87.18

Table 6.9. *Rewriting Table 6.6 as ranks*

Domain	Classifier f_A	Classifier f_B	Classifier f_C
1	1	3	2
2	1.5	3	1.5
3	1	3	2
4	1	3	2
5	2	3	1
6	1	3	2
7	2	3	1
8	2	3	1
9	2	3	1
10	2	3	1
Rank Sums ($R_{.j}$)	15.5	30	14.5

Illustration

Exemple pour trois algorithmes f_A , f_B et f_C

Table 6.9. Rewriting Table 6.6 as ranks

Domain	Classifier f_A	Classifier f_B	Classifier f_C
1	1	3	2
2	1.5	3	1.5
3	1	3	2
4	1	3	2
5	2	3	1
6	1	3	2
7	2	3	1
8	2	3	1
9	2	3	1
10	2	3	1
Rank Sums ($R_{.j}$)	15.5	30	14.5

$$q_{12} = \frac{\bar{R}_{.1} - \bar{R}_{.2}}{\sqrt{\frac{3(3+1)}{6 \times 10}}} = \frac{15.5 - 30}{\sqrt{\frac{3(3+1)}{6 \times 10}}} = \frac{-14.5}{0.45} = -32.22,$$

$$q_{13} = \frac{\bar{R}_{.1} - \bar{R}_{.3}}{\sqrt{\frac{3(3+1)}{6 \times 10}}} = \frac{15.5 - 14.5}{\sqrt{\frac{3(3+1)}{6 \times 10}}} = \frac{1}{0.45} = 2.22,$$

$$q_{23} = \frac{\bar{R}_{.2} - \bar{R}_{.3}}{\sqrt{\frac{3(3+1)}{6 \times 10}}} = \frac{30 - 14.5}{\sqrt{\frac{3(3+1)}{6 \times 10}}} = \frac{15.5}{0.45} = 34.44.$$

Ici **CD = 2,55** (Critical Difference)

Donc $f_B > f_A$, et $f_B > f_C$, mais pas $f_A > f_C$

Illustration

- Reprenons la comparaison :
- Table de valeurs critiques

α	k									
	2	3	4	5	6	7	8	9	10	
0.05	1.960	2.344	2.569	2.728	2.850	2.949	3.031	3.102	3.164	
0.10	1.645	2.052	2.291	2.459	2.589	2.693	2.780	2.855	2.920	

Data set	Algorithm A	Algorithm B	Algorithm C
D_1	1	2	3
D_2	1	2.5	2.5
D_3	1	2	3
D_4	1	2	3
Average rank	1	2.125	2.875

Exemple pour 3 algorithmes et 4 jeux de données

- On a alors :

Ici, A est significativement meilleur que C





Illustration : test de Nemenyi




Les méthodes sont **triées par rang moyen** (de la gauche vers la droite) et les groupes de méthodes non significativement différents sont **connectés** (p-value > 0.05)

[Sebastian Pölsterl et al. (2017) "Heterogeneous ensembles for predicting survival of metastatic, castrate-resistant prostate cancer patients", F1000Research.]

Illustration

- Comparaison de 11 algorithmes sur ~30 jeux de données




Comparaison des rangs moyens

ATTENTION : ne dit rien sur les performances


Peut-être qu'il y a très peu de différences !

Illustration

- Comparaison de 11 algorithmes sur ~30 jeux de données



Comparaison des rangs moyens



Pour $\alpha = 0.5$, on voit 4 algorithmes se détacher

Sources

- Peter Flach (2012) [Machine Learning. The Art and Science of Algorithms that Make Sense of Data](#). Cambridge University Press.
- Nathalie Japkowicz & Mohak Shah (2011) [Evaluating Learning Algorithms. A classification perspective](#). Cambridge University Press.
- Demsar, J. (2006) [Statistical Comparison of Classifiers over Multiple Data Sets](#). *Journal of Machine Learning Research* 7:1-30.