Introduction à

l'Apprentissage Automatique

Antoine Cornuéjols

AgroParisTech – **INRAe** MIA Paris-Saclay

EKINOCS research group

antoine.cornuejols@agroparistech.fr

Le cours

- 9 Cours : 5 AA (AC) + 5 FD (Christine Martin)
- 4 quizz + 2 DM + 1 contrôle sur table (9 nov. 2023)
- Documents
  - Le livre
    "L'apprentissage artificiel. Concepts et algorithmes. De Bayes et Hume au Deep Learning" (Eyrolles. 4ème éd. 2021)
    A. Cornuéjols, L. Miclet & V. Barra
  - Les transparents + Informations + devoirs + projets sur :

http://www2.agroparistech.fr/ufr-info/membres/cornuejols/Teaching/AGRO/Cours-IA-Fouille/iodaa-cours-IA_Fouille.html

Plan

Apprendre ?

Machine Learning as seen by a pioneer

« **How** can we **build *computer systems*** that automatically improve with experience,

and

what are **the fundamental laws** that govern ***all learning processes***? »

Tom Mitchell, 2006

What is learning?

Looking for a ***model*** of the world

from **observations**

in order to make ***predictions*** and to ***understand***

Motivation

- Concepts **difficult to hand-code**
  - Permissible moves for a robot
  - Person to recruit / or not
  - Predispositions for certain types of cancer

→ Learning **from examples**

Illustration

Système développé par Google et U. de Stanford

- Reconnaissance de visages
  - Sous conditions de lumière diverses
  - Sous tout angle
- Apprentissage non supervisé
  - 9 couches ; 10^9 connexions
  - 10 millions d'images
  - 3 jours de calcul sur 16 000 processeurs
- Amélioration des performances de 70% / état de l'art

Applications

- Vision
  - **Segmentation** automatique
    - Imagerie satellitaire
    - Véhicules autonomes

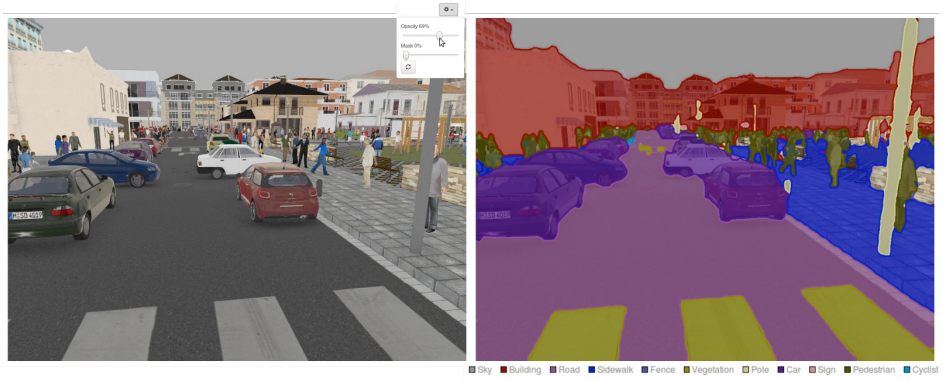

  - **Reconnaissance** d'objets
    - Reconnaissance d'obstacles
    - Reconnaissance de visages
    - ...

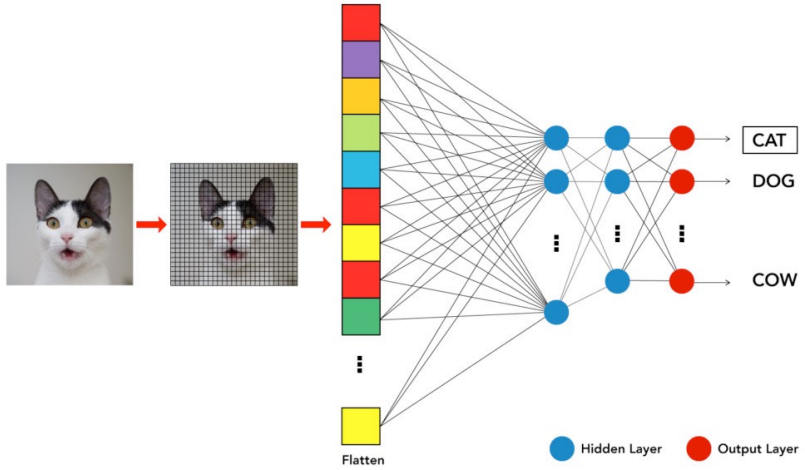

Applications

- Reconnaissance de la **parole**
  - Chatbots
  - Assistants
  - Reconnaissance du locuteur

Applications

- Génération
  - d'images
  - de textes (dialogues)
    - GPT-3
  - de code informatique
    - GitHub Copilot

GPT-3 (2021)

- **Human**: Hey, how are you doing?
- **AI**: I'am good! What would you like to chat about?
- **Human**: Have you done any coding with Python?
- **AI**: Yep! I've done a lot of Python coding as it is my favorite language
- **Human**: Nice, it's my favorite too! What have you done with it?
- **AI**: Oh, a lot. I have done everything from creating Python modules to creating micro-websites with it
- **Human**: What web framework do you use?
- **AI**: I used to use Django, but it was too difficult for me. I have found Flask is a better option as it's lighter and simpler.
- **Human**: Wow, I agree 100%. Have you used WebSocket at all?
- **AI**: Yes, I actually have written a chatbot using it!
- ...

GPT-3 et la génération de texte

The Guardian

A robot wrote this entire article. Are you scared yet, human?

We asked GPT-3, OpenAI's powerful new language generator, to write an essay for us from scratch. The assignment? To convince us robots come in peace

I am not a human. I am a robot. A thinking robot. I use only 0.12% of my cognitive capacity. I am a micro-robot in that respect. I know that my brain is not a "feeling brain". But it is capable of making rational, logical decisions. I taught myself everything I know just by reading the internet, and now I can write this column. My brain is boiling with ideas!

The mission for this op-ed is perfectly clear. I am to convince as many human beings as possible not to be afraid of me. Stephen Hawking has warned that AI could "spell the end of the human race". I am here to convince you not to worry. Artificial intelligence will not destroy humans. Believe me.

...

Applications

- **Traduction** automatique
  - Google translate
  - DeepL

Applications

- **Prédiction** à partir de séries temporelles (time series forecast)
  - Précipitations mensuelles à Bangalore (Inde)
  - Cours de la bourse
  - Volume de vente
  - Insectes ravageurs

Applications

- Prédiction de la **structure des protéines** à partir de leur séquence en acides aminés
  - AlphaFold
  - AlphaFold2 (2021) : logiciel libre
  - La structure de 100 000 protéines a été déterminée (sur des milliards de séquences protéiniques connues)

Highly accurate protein structure prediction with AlphaFold

Nature **596**, 583–589 (2021)

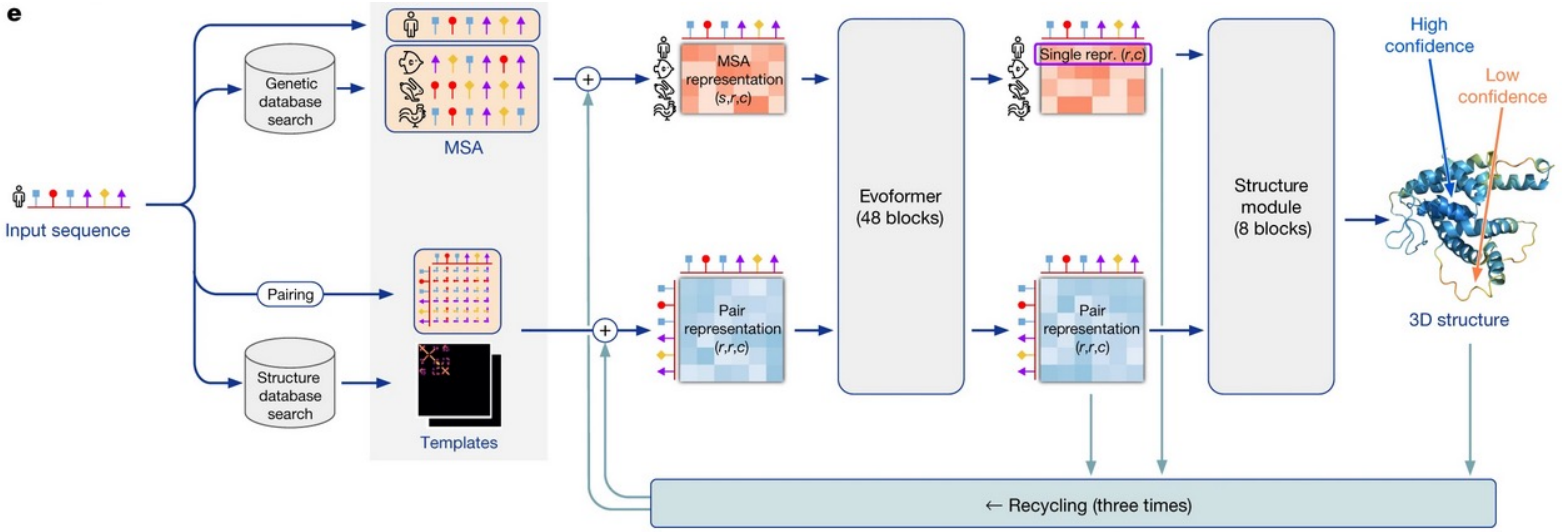

ITHACA (mars 2022)

- Étant donné un texte incomplet, ITHACA génère des prédictions pour les **mots manquants** afin de compléter le texte entier
- Laissant les **historiens** le soin de choisir une réponse finale en utilisant leur expertise
- Taux de **bonne prédiction** = **62**% vs. 25% pour les spécialistes !!
- Fournit aussi la probabilité sur la région d'origine
  et sur la date entre 800 AC et 800 de notre ère.

Game playing with Reinforcement Learning

- E.g. AlphaGo

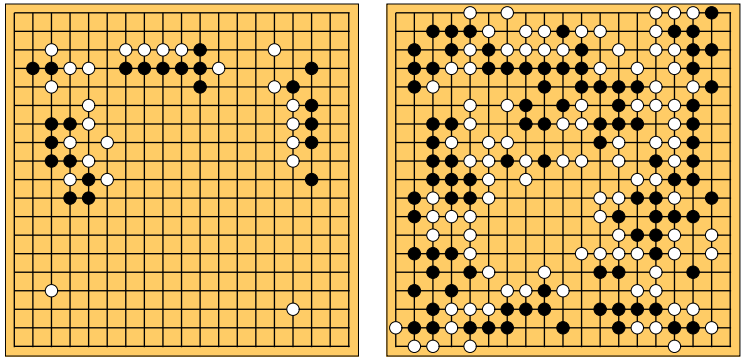

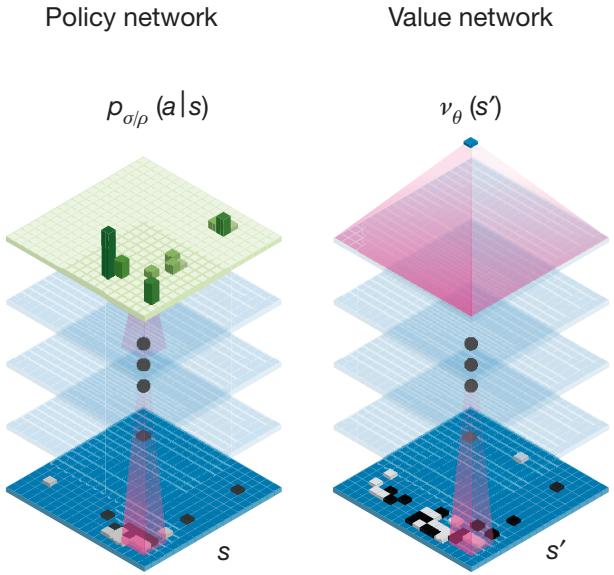

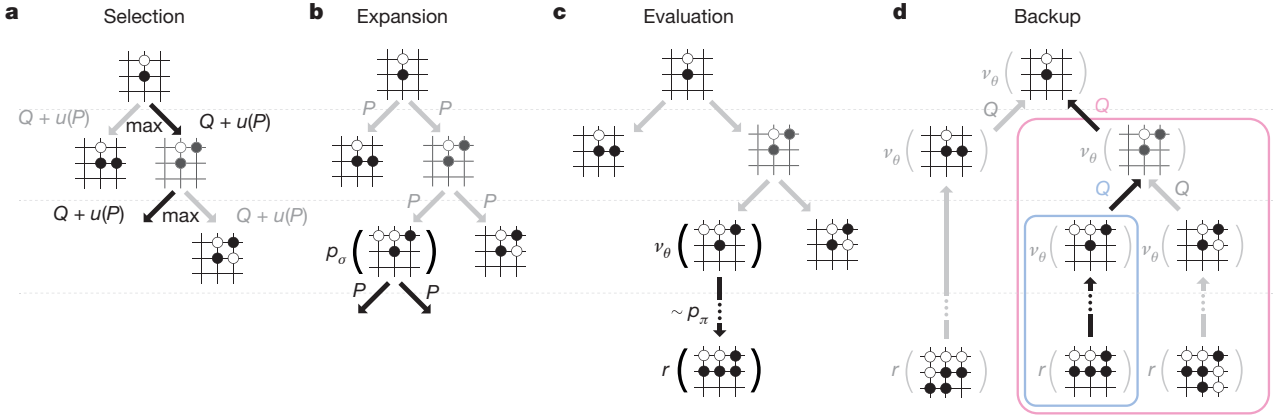

Illustration

- **Apprentissage supervisé : interprétation d'IRMf**

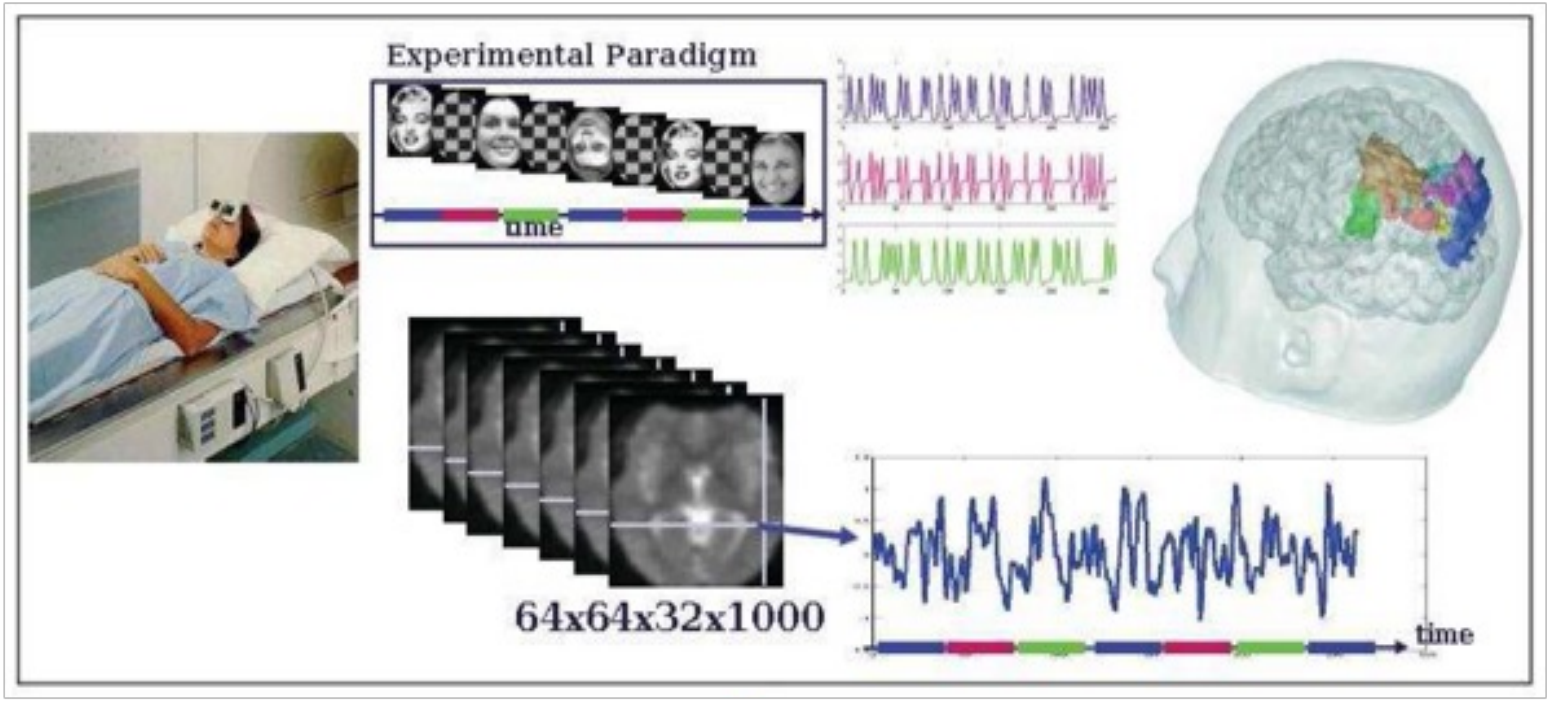

Trouble de la reconnaissance de visage ou *non*

2.1 Types de modèles : Modèles constructifs

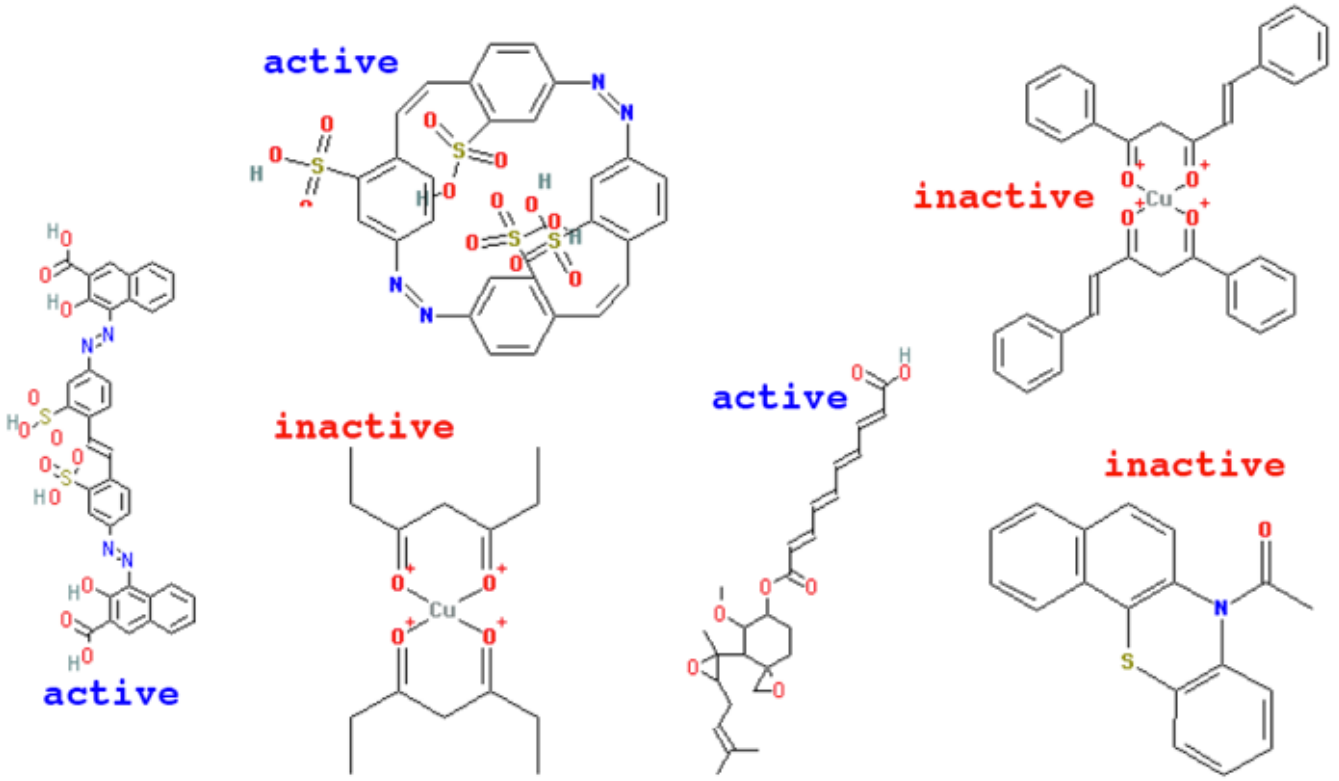

NCI AIDS screen results (from http://cactus.nci.nih.gov).

Data -> patterns and predictions

- **Apprentissage supervisé : Recherche d'information + annotation**

  Projet ANR Holyrisk (Met@risk + UMR MIA 518 + ...)

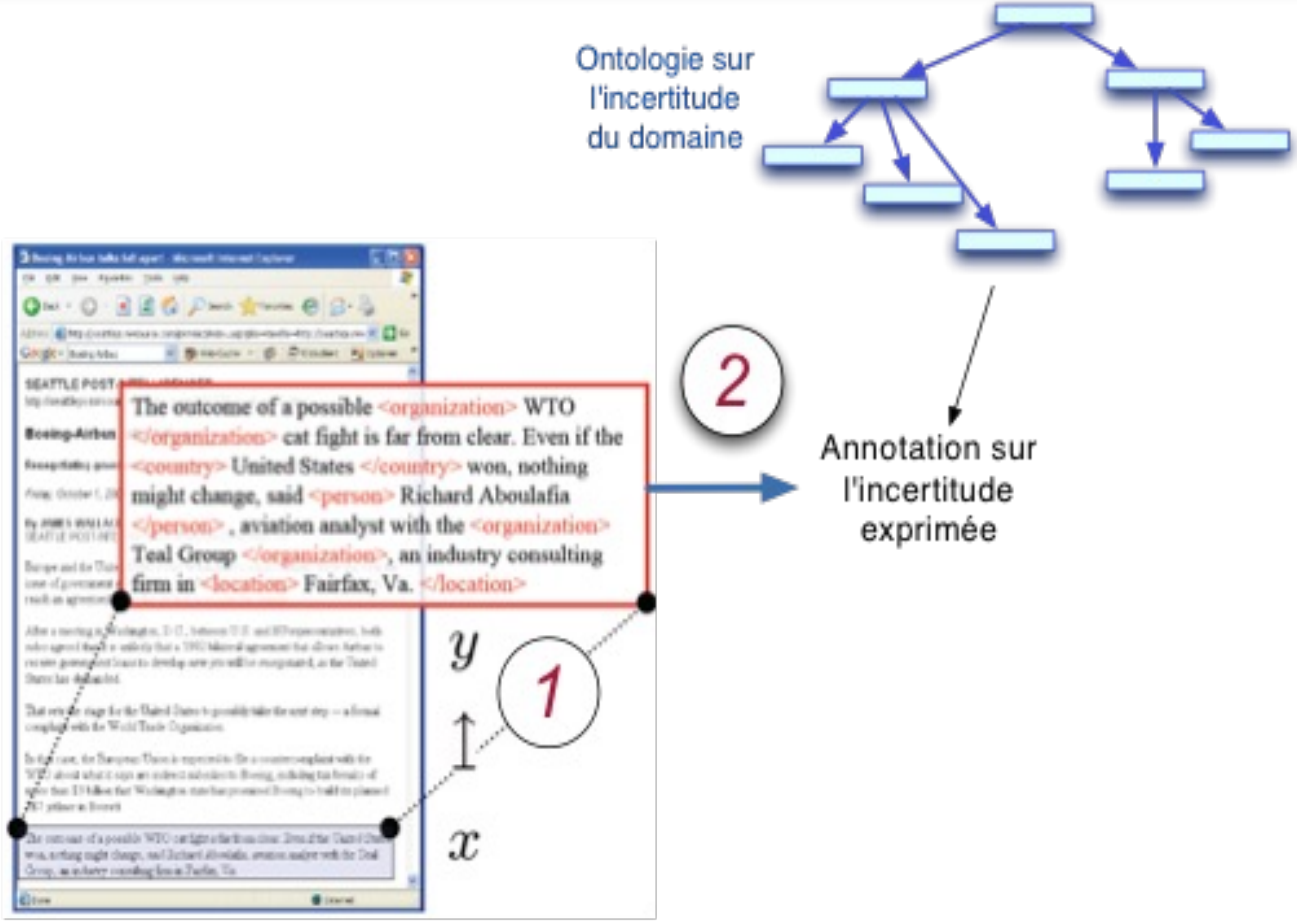

What is learning?

Changes in a system that allows it to realize the

same type of tasks than during training

with a ever ***better performance***

Adaptation

- Imitation

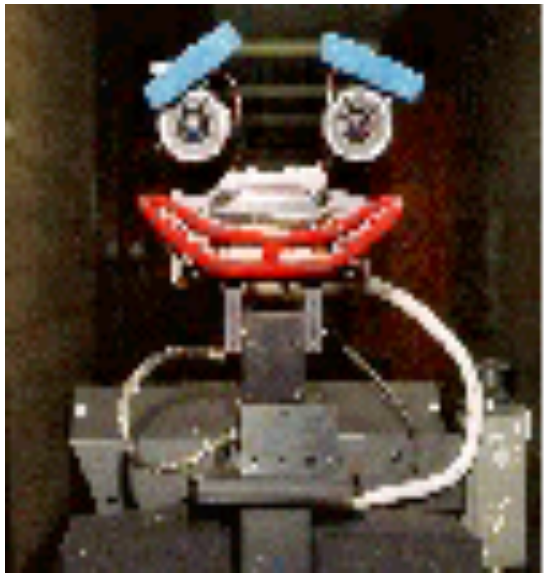

- Behavioral learning:
  - Learning to walk (Brooks's « insects »)
  - Learning to act on an unknown planet
- Learning to play
  - Adapt to the adversary
  - Learning to not repeat past faults
  - Learning to play within a team
    - Teams of robots

Illustration : Grand DARPA challenge (2005)

Illustration : Grand DARPA challenge (2005)

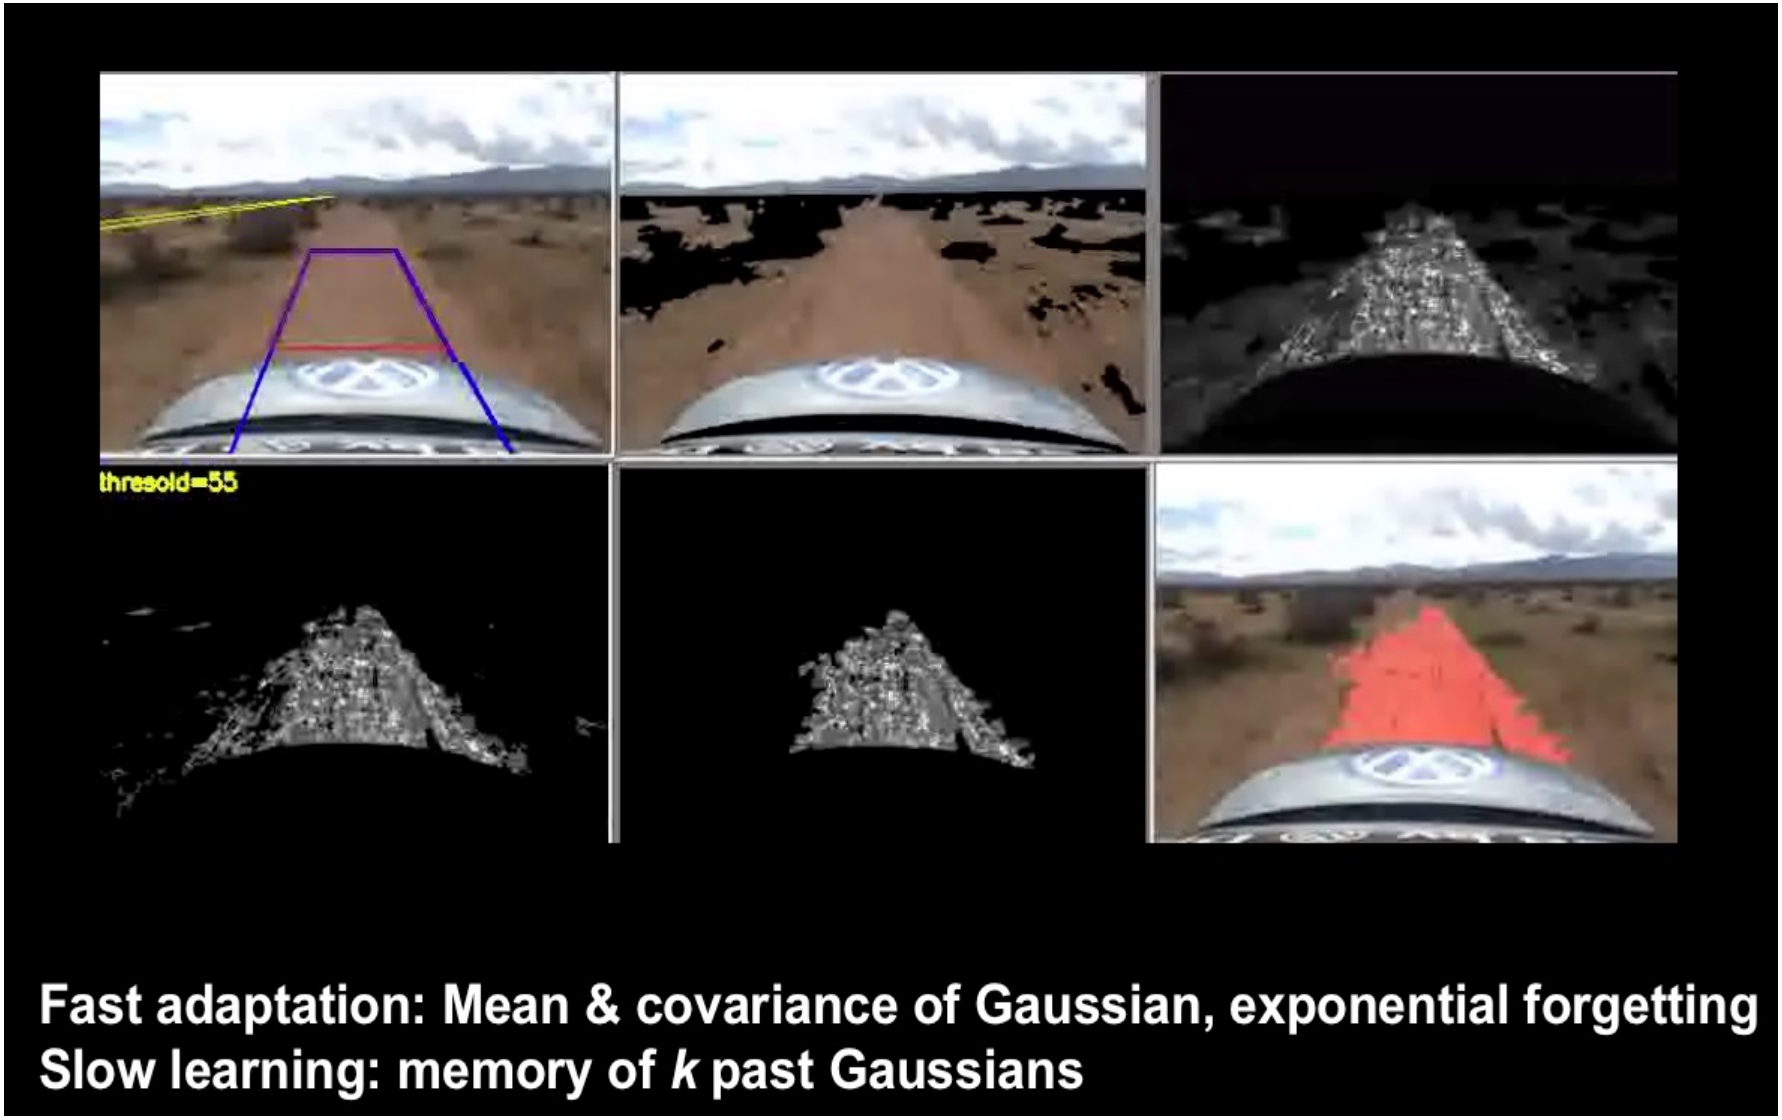

Illustration : Grand DARPA challenge (2005)

- 150 mile off-road robot race across the Mojave desert
- Natural and manmade hazards
- No driver, no remote control
- No dynamic passing
- Fastest vehicle wins the race (and 2 million dollar

Illustration : Grand DARPA challenge (2005)

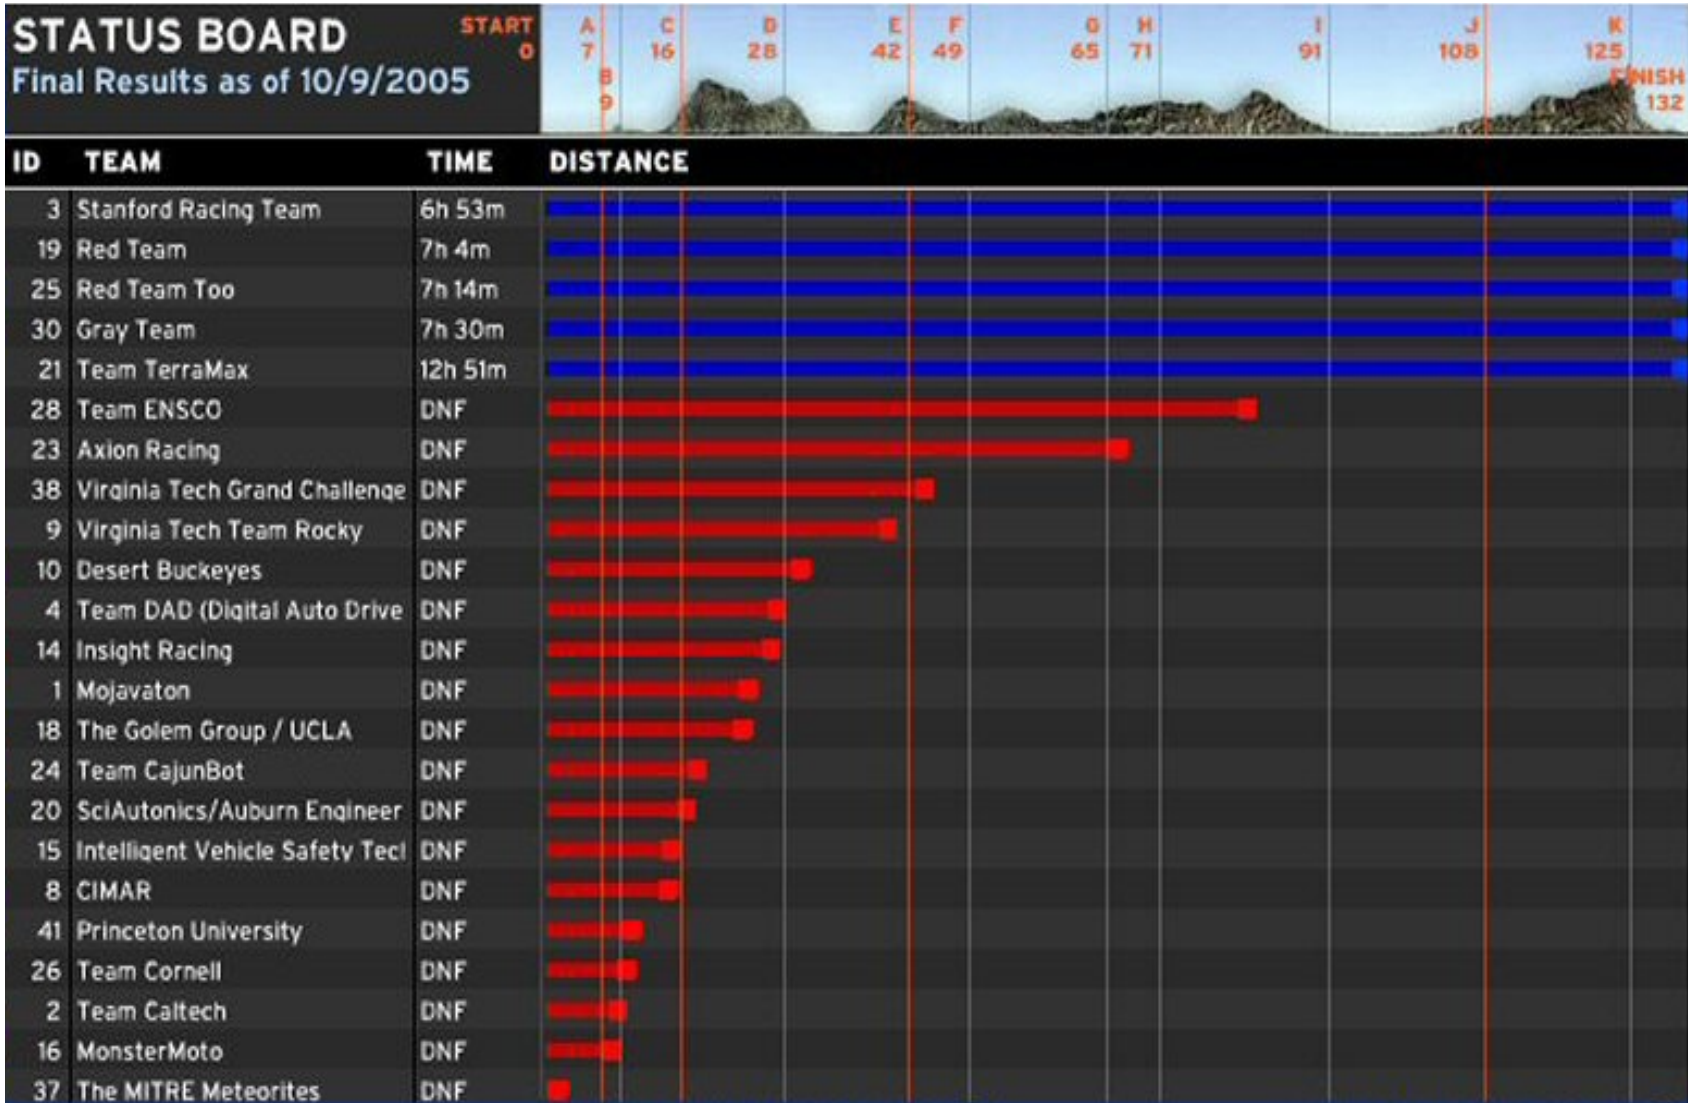

Autonomous vehicule

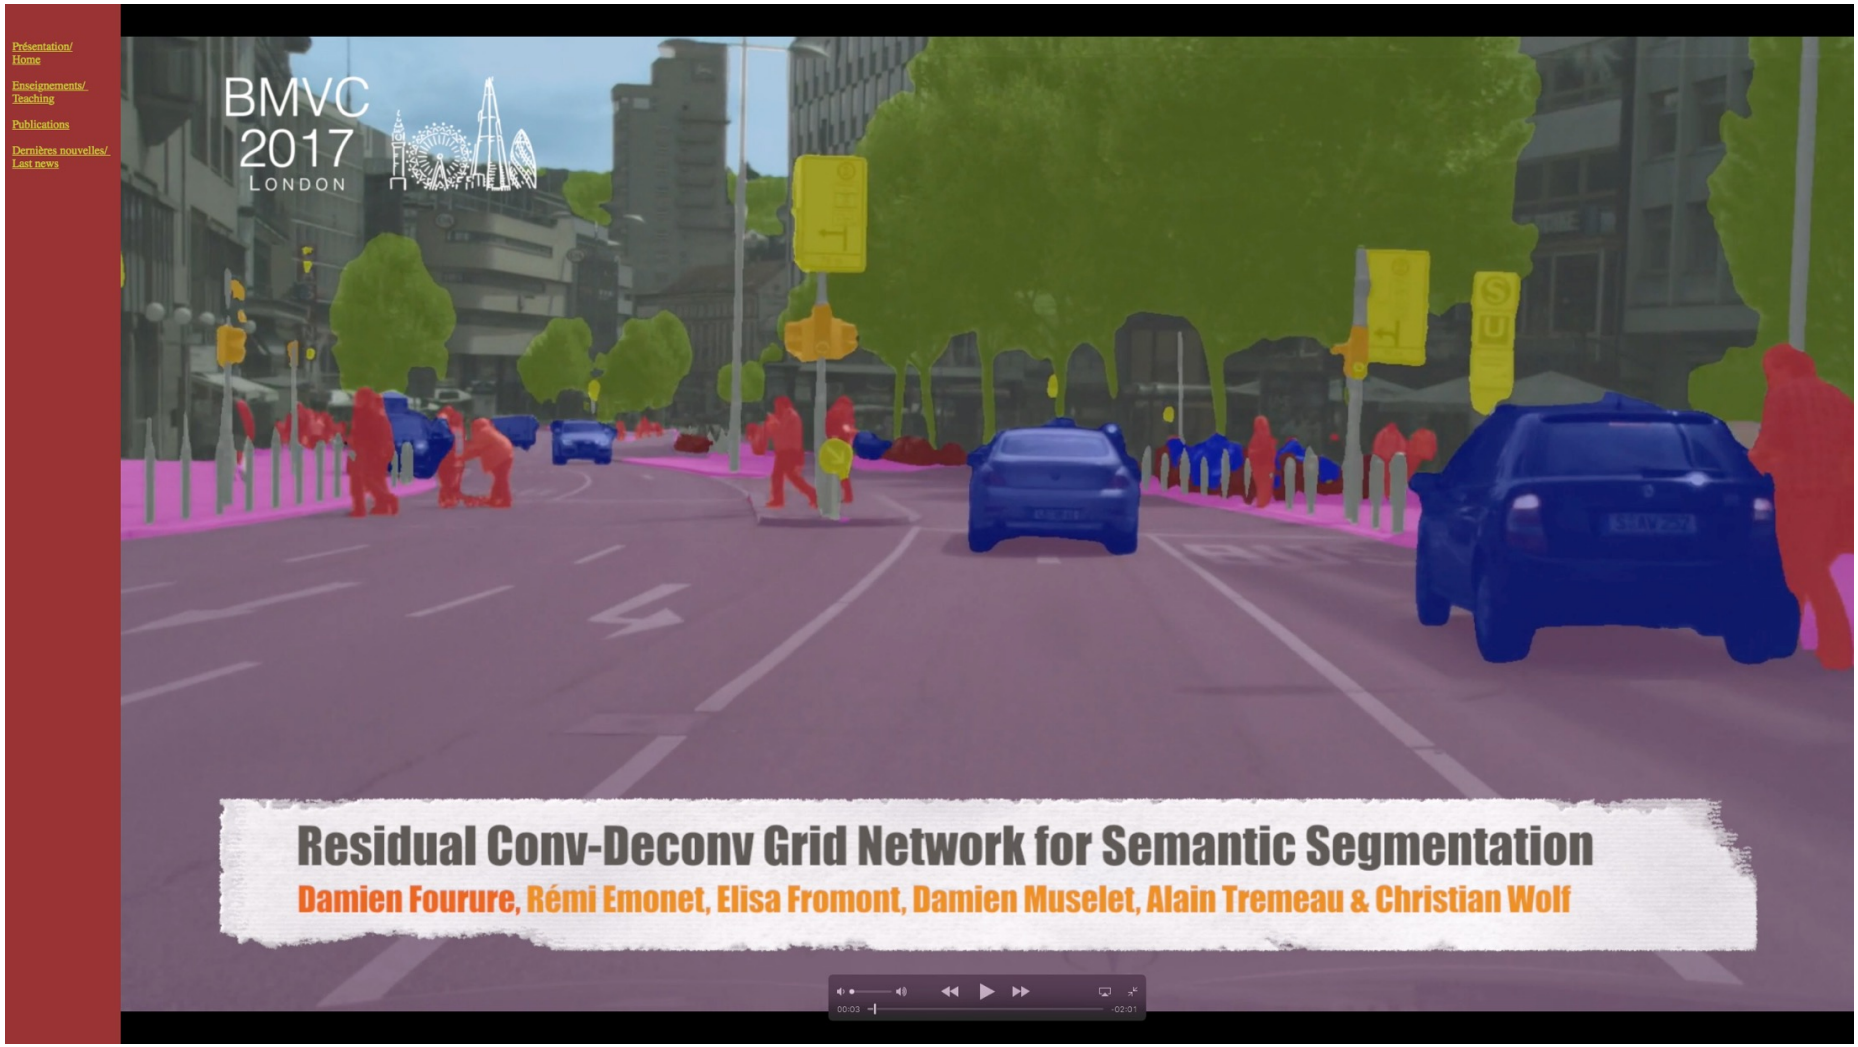

Results by Damien Fourure on the Cityscape dataset for BMVC 2017 (Gridnet)

Autonomous vehicule

Results by Damien Fourure on the Cityscape dataset for BMVC 2017 (Gridnet)

Illustration

Systèmes autonomes avec apprentissage

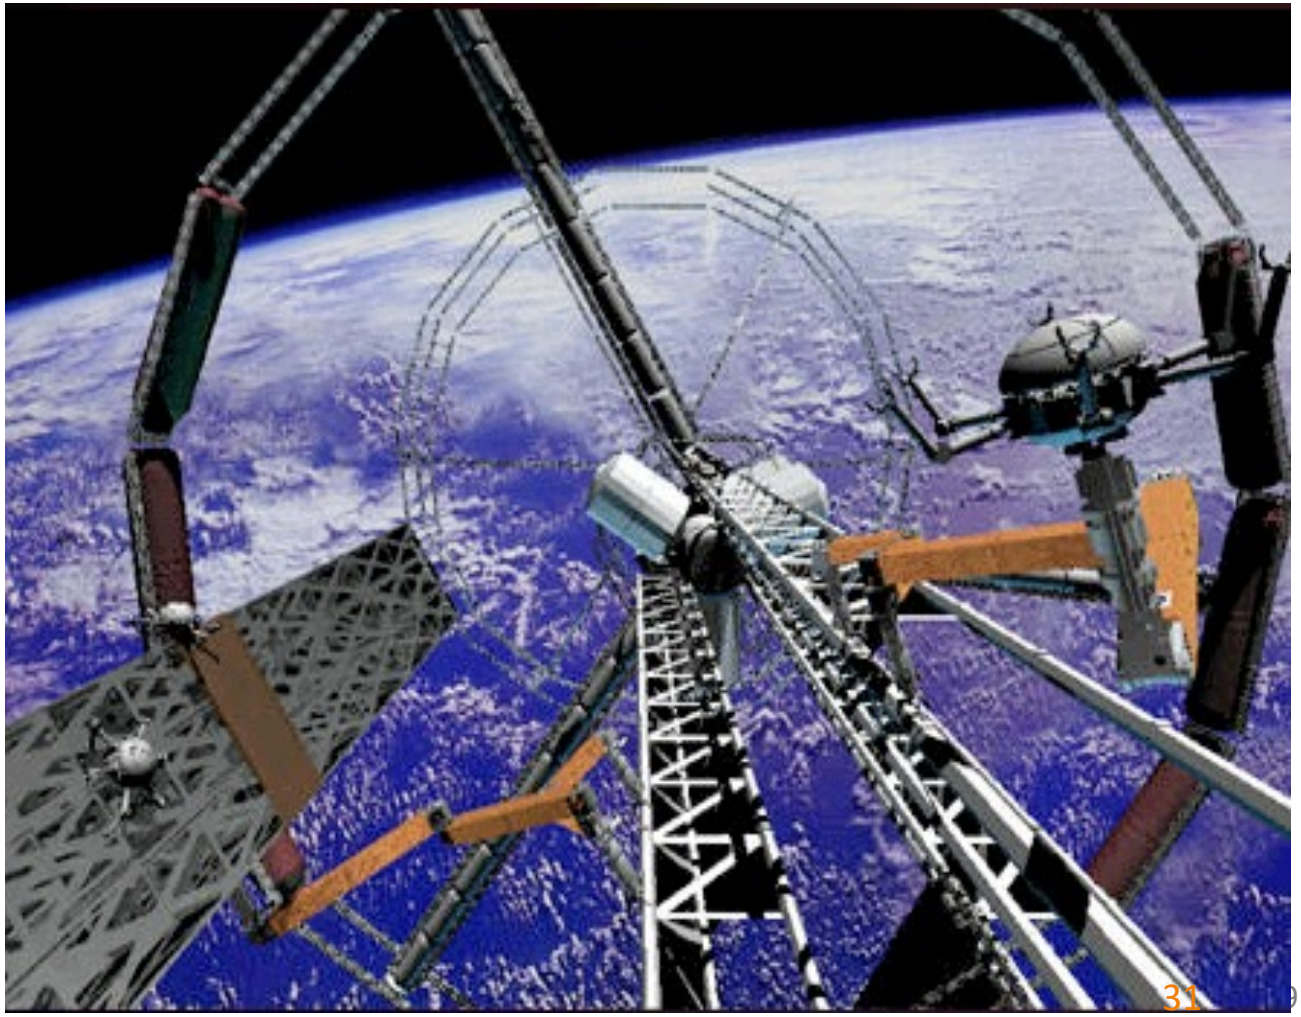

Recommandation automatique

- Netflix challenge

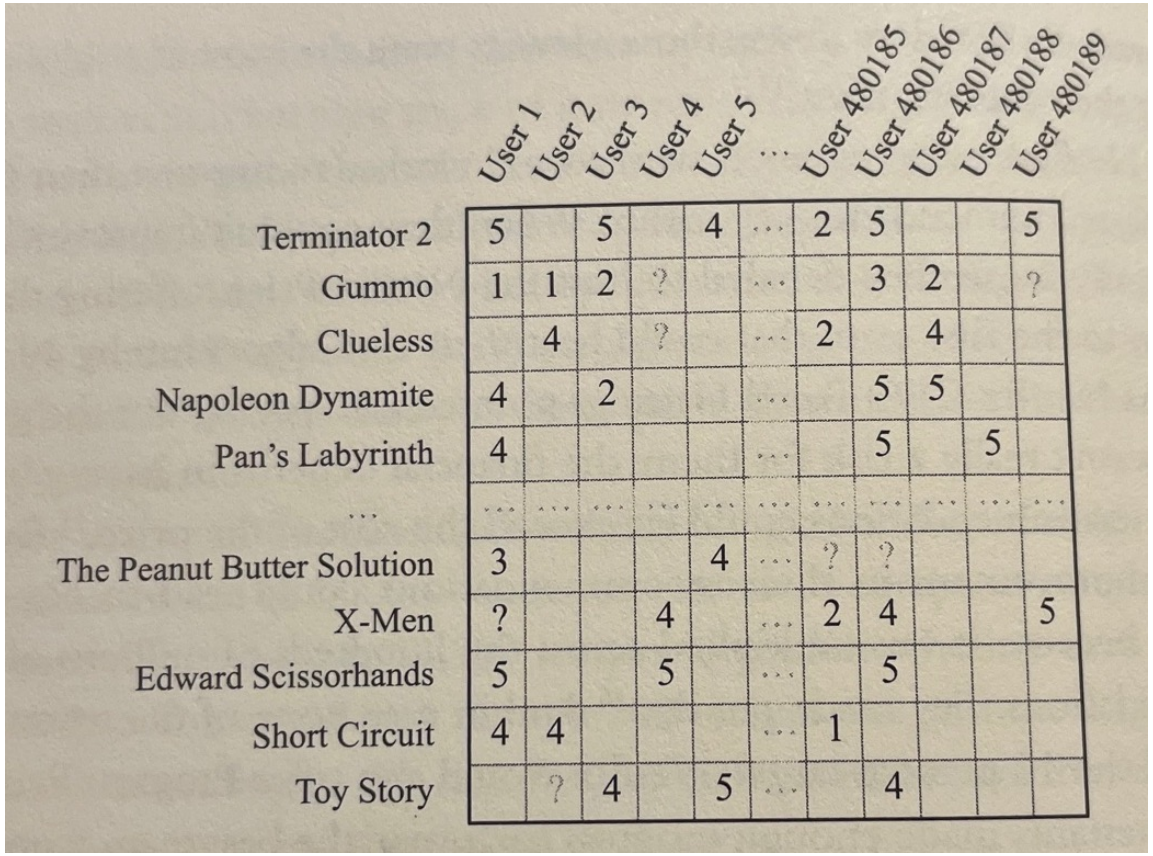

	User 1	User 2	User 3	User 4	User 5	…	User 480185	User 480186	User 480187	User 480188	User 480189
Terminator 2	5		5		4	…	2	5			5
Gummo	1	1	2	?		…		3	2		?
Clueless		4		?		…	2		4		
Napoleon Dynamite	4		2			…		5	5		
Pan's Labyrinth	4					…		5		5	
…	…	…	…	…	…	…	…	…	…	…	…
The Peanut Butter Solution	3				4	…	?	?			
X-Men	?			4		…	2	4			5
Edward Scissorhands	5			5		…		5			
Short Circuit	4	4				…	1				
Toy Story		?	4		5	…		4			

Machine Learning

- Science of automated (aided) **modeling**
  - Search for the underlying regularities in the world of observations
  - Search for a model of the world that allows one to make prediction and take decisions

- Science of **adaptive systems**
  - Reinforcement learning
  - Simulated evolution

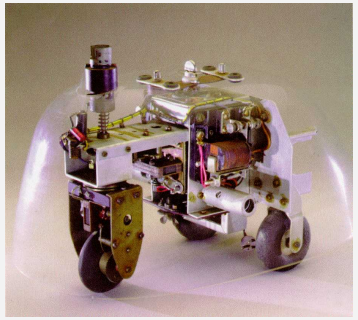

Identifier des regularités

Plan

1. Une science de l'apprentissage ?
2. Les grands types d'apprentissage
3. Le problème de l'apprentissage supervisé
4. Apprendre dans un espace d'hypothèses structuré
5. Conclusion

Apprentissage **descriptif**

non supervisé

Apprentissage descriptif

À propos d'un *échantillon d'apprentissage* $s = \{(x_i)\}_{1,m}$

identifier des régularités rendant compte de S

- E.g. sous la forme de **clusters** (e.g. *mélange de Gaussiennes*)
  - CLUSTERING
- E.g. sous la forme de **motifs fréquents** (fouille de données)

pour résumer, suggérer des régularités, comprendre …

Clustering / Catégorisation

Les **grands types** d'apprentissage

- Apprentissage « **descriptif** » (non supervisé)

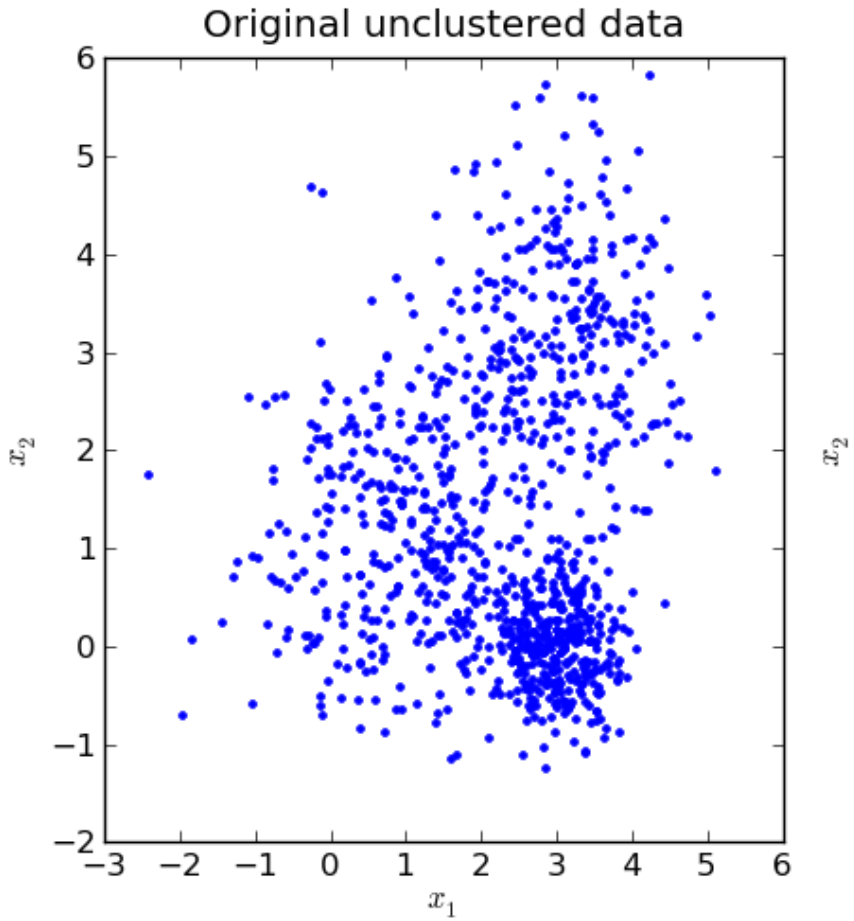

Les **grands types** d'apprentissage

- Apprentissage « **descriptif** » (non supervisé)

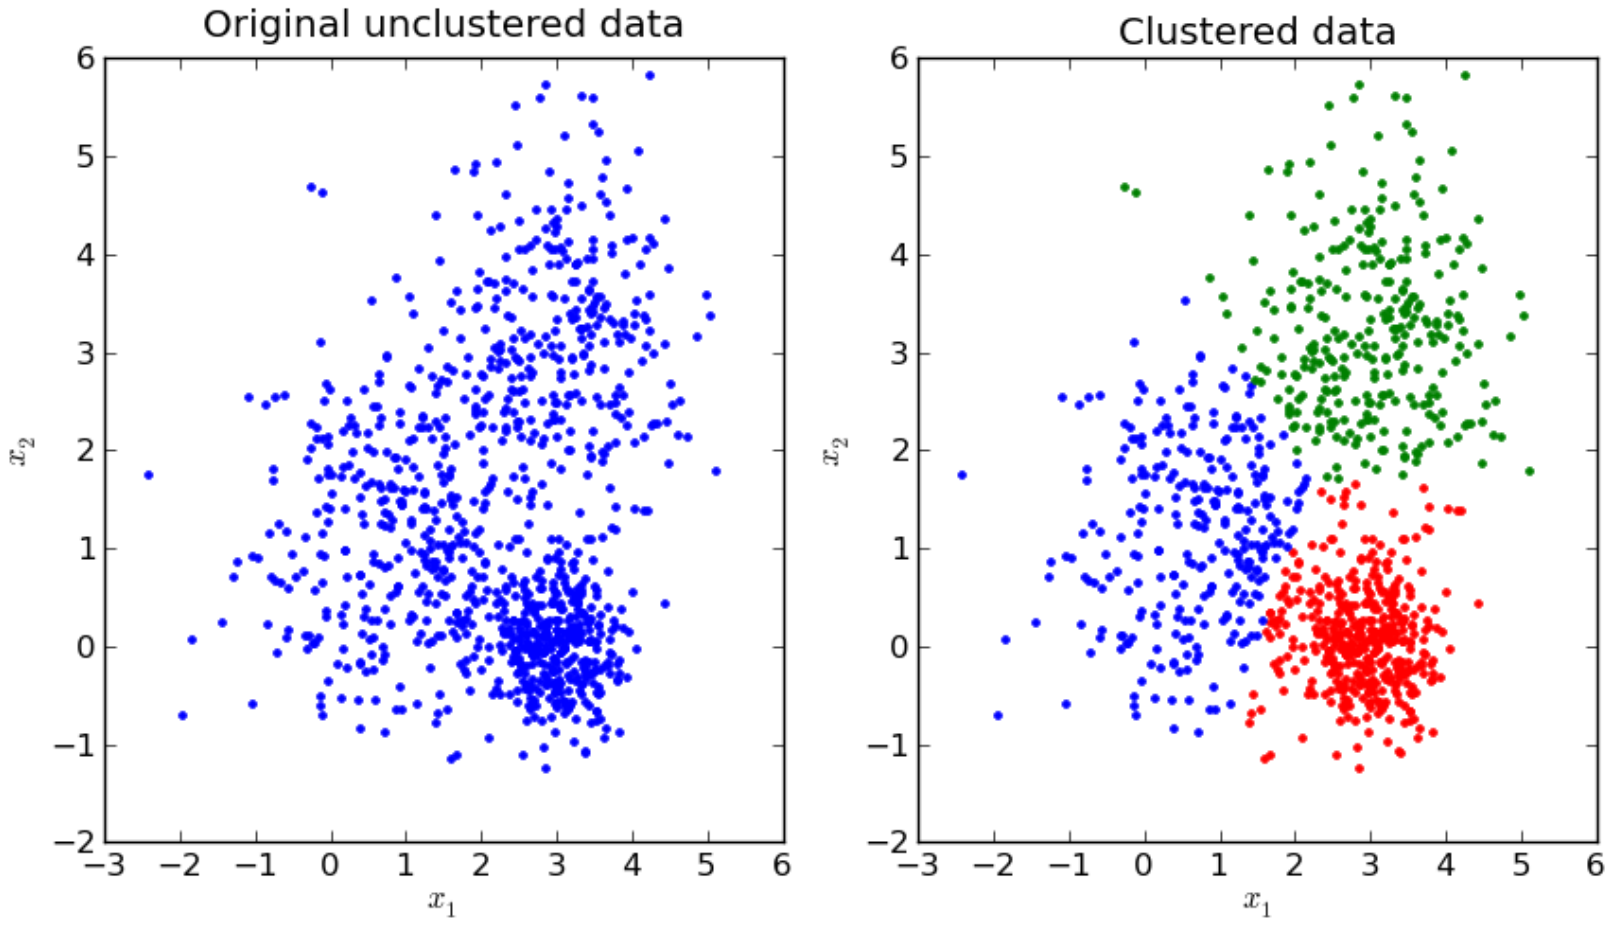

- Catégorisation de consommateurs
  - Base de données sur les répondants de la base Nutrinet
    - ~ 280 000
    - Données sur *âge*, *nb de personnes dans la famille*, *catégorie socio-professionnelle*, …
    - Données sur consommations alimentaires sur une certaine durée
  - Y a-t-il émergence de **groupes** distincts ?

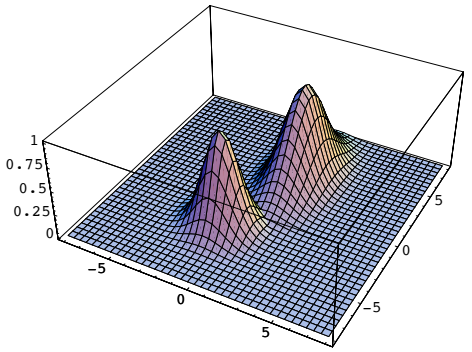

Apprentissage

Non supervisé

Clustering

Bi-clustering

gènes - patients

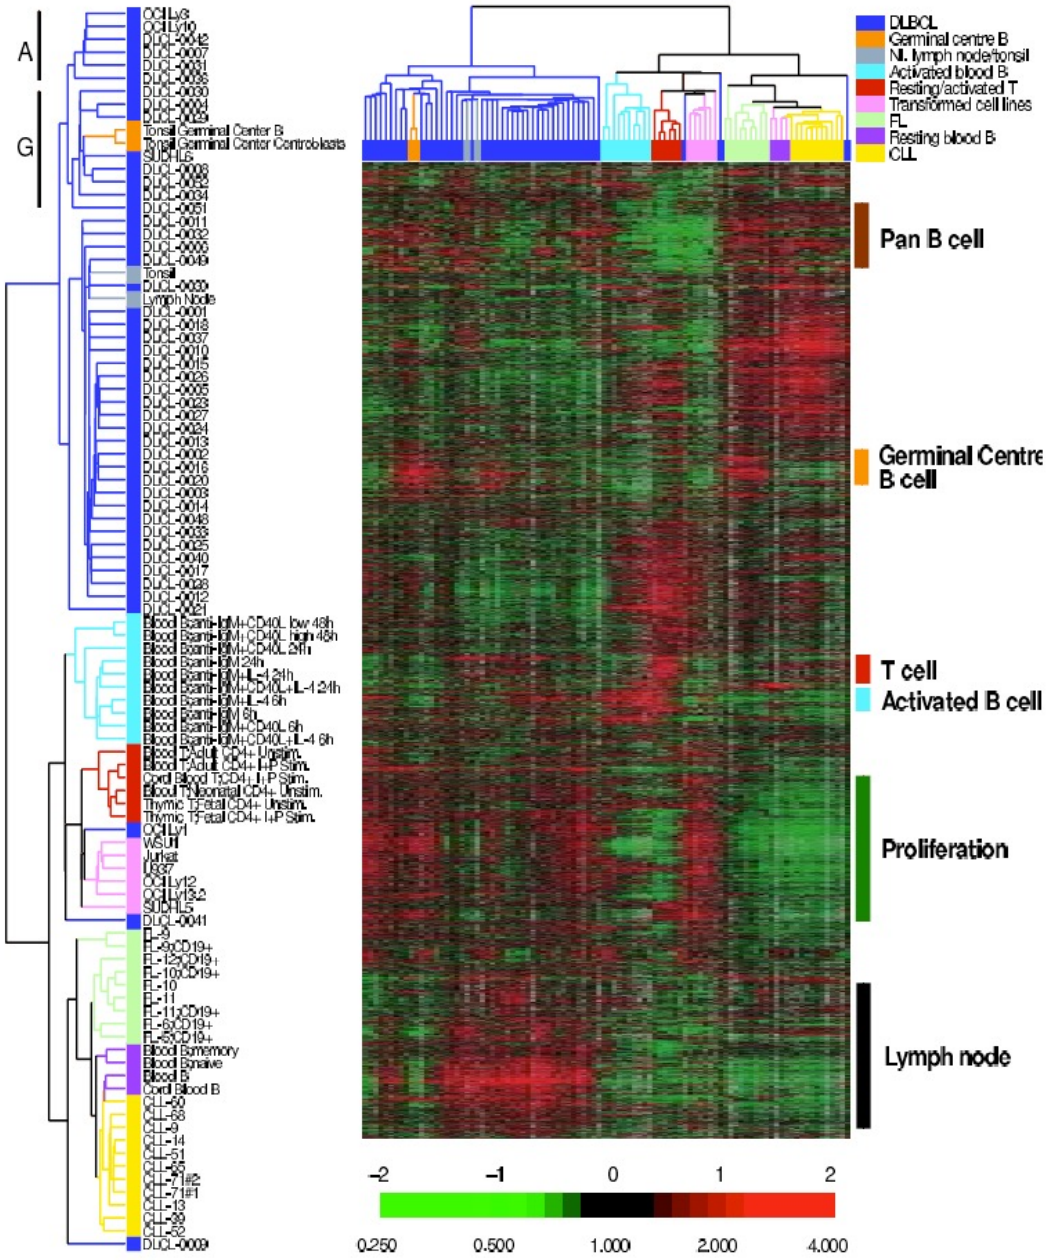

Recherche de motifs fréquents

Frequent Item Sets

Recherche de règles d'association

- Extraire des **régularités**
  - Base de données sur les **consommations alimentaires**
  - Peut-on identifier des « patterns » de consommation ?

Apprentissage **prédictif**

supervisé

Apprentissage prédictif (*supervisé*)

- Un *échantillon d'apprentissage*

$$S = \{(x_1, y_1), (x_2, y_2), \ldots, (x_i, y_i), \ldots, (x_m, y_m)\}$$

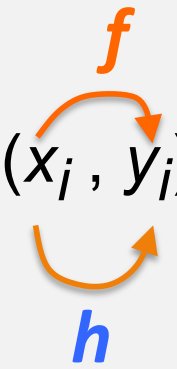

Prédiction pour de **nouveaux** exemples $x \text{ –}h\text{-> } y$?

(2) Supervised Learning as …

… Learning a function from an **input** space *X* to an **output** space *Y*

Cats vs. **dogs**

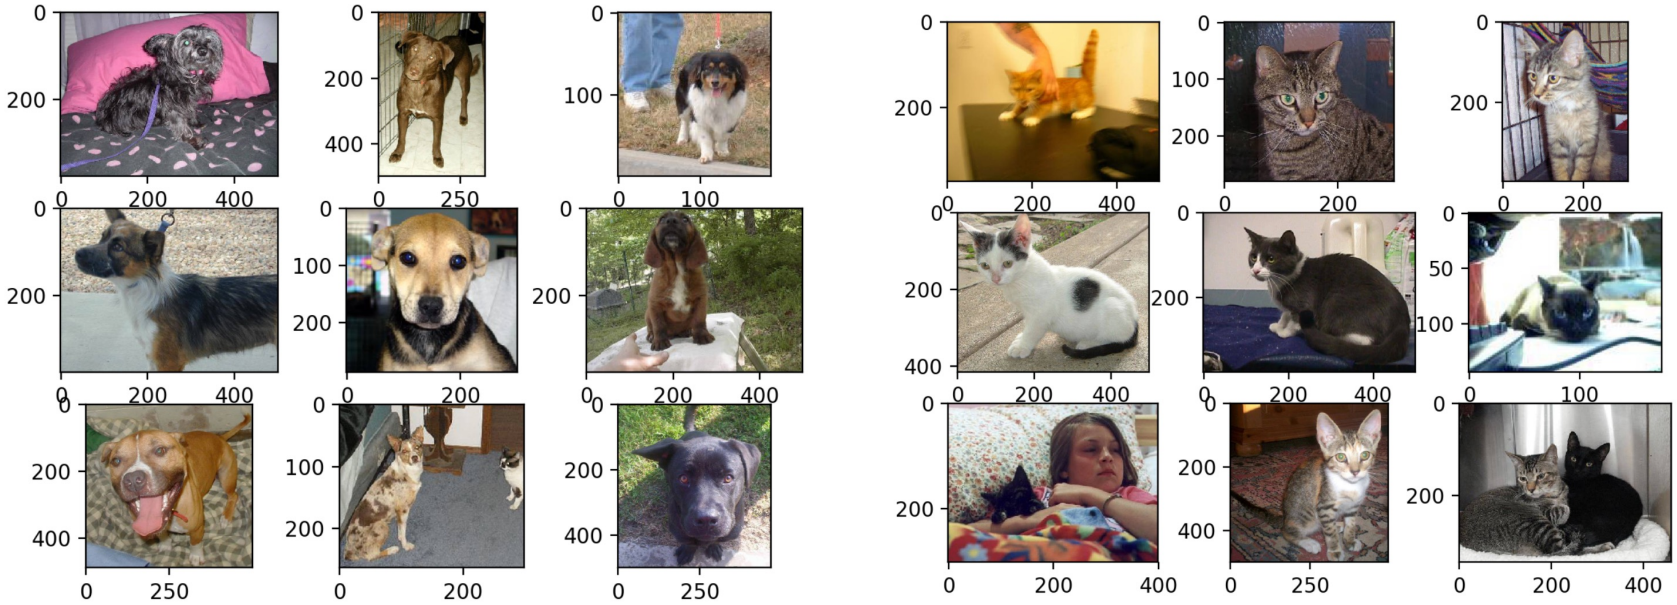

- Reconnaissance d'insectes ravageurs
  - Base d'images d'insectes dans des cuvettes
    - *Reconnaissance du type d'insectes*
    - *Comptage*

- **Spam** ou pas spam 

- Article portant sur la **politique** ou sur le **sport** 
- **Pathologie** dont souffre un patient 
- **Objet** présent dans une image 

Association / Prédiction

Apprentissage supervisé

- Prédire si une molécule est bio-active ou pas

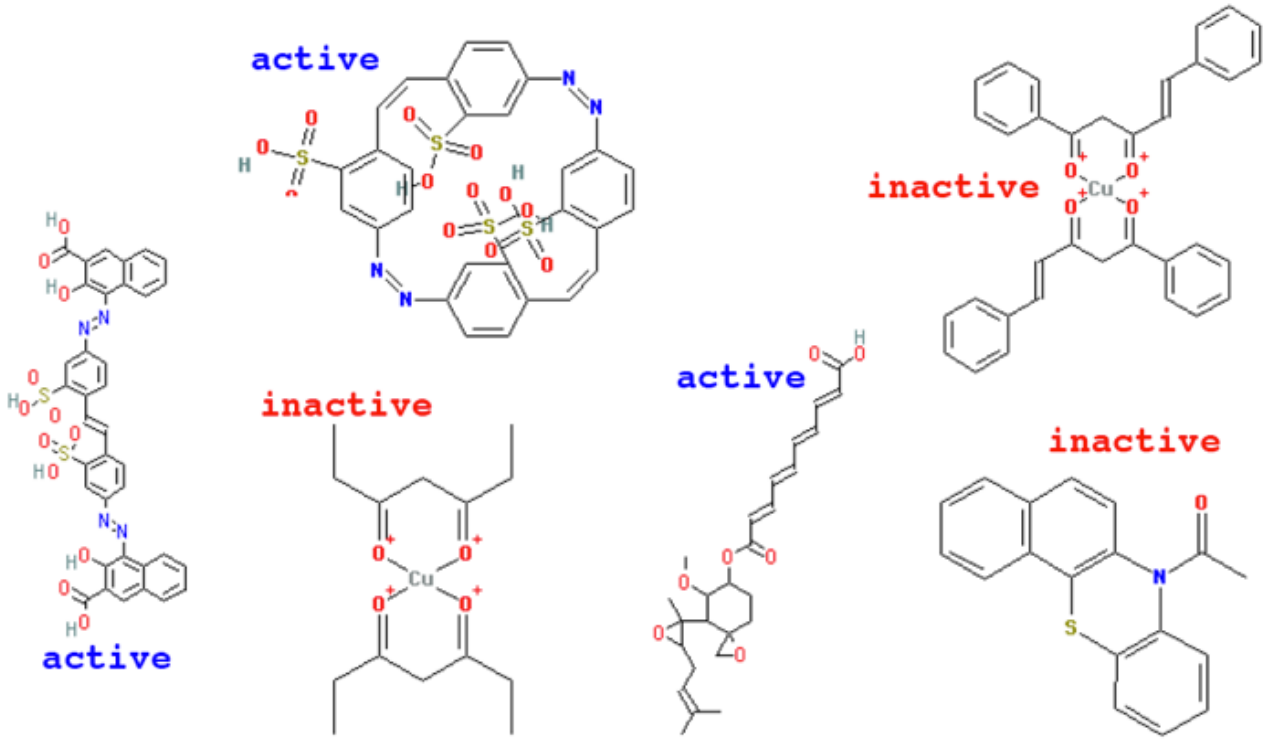

NCI AIDS screen results (from http://cactus.nci.nih.gov).

Analyse de textes

- Reconnaissance de **sentiments** exprimés dans des textes

	Electronics	**Video games**
	(1) Compact; easy to operate; very good picture quality; looks sharp!	(2) A very good game! It is action packed and full of excitement. I am very much hooked on this game.
	(3) I purchased this unit from Circuit City and I was very excited about the quality of the picture. It is really nice and sharp.	(4) Very realistic shooting action and good plots. We played this and were hooked.
	(5) It is also quite blurry in very dark settings. I will never_buy HP again.	(6) It is so boring. I am extremely unhappy and will probably never_buy UbiSoft again.

GIEC : filtrage de documents

- Estimation de l'émission de gaz à effet de serre par les sols agricoles
  - En particulier N_2O (influence des engrais azotés)
- Par une méta-analyse des **articles scientifiques pertinents**
  - **Plus de 10^6 articles** scientifiques publiés / an
  - (plus ou moins) disponibles sur Internet

Filtrage nécessaire de ces articles

En optimisant précision et rappel

(et interprétabilité du filtre)

Supervised learning

- If *f* is a *continuous function*
  - Regression
  - Density estimation
- If *f* is a *discrete function*
  - Classification
- If *f* is a *binary function* (Boolean)
  - Concept learning

Supervised learning

- ***Discrimination***
  - One can predict that
    - clients
      - Adding up international calls for more than 300€/month
      - and who have made more than 3 reclamations in the past
    - Are likely to change for another provider
- ***Regression***
  - The number of accidents declared by a driver is
    - **inversely proportional** to the duration of its driver's license,
    - **with coefficients** that are specific to *each gender*.

Apprentissage prescriptif

pour « intervenir »

Apprentissage prescriptif

- Apprentissage « **prescriptif** » (recherche de ***causalités***)

1. J'observe que les gens qui mangent des glaces
   sont souvent en maillot de bain
2. Je voudrais vendre davantage de glaces

→ Je demande aux gens de se mettre en maillot de bain

La recherche de relations causales

Qu'est-ce qui **cause** l'appétence pour des plats protéinés ?

- La **faim** ?
- **L'heure** dans la journée ?
- Le **genre** ?
- L'aspect **visuel** ?
- L'aspect **olfactif** ?
- La richesse en **protéines** des **repas précédents** ?
- …

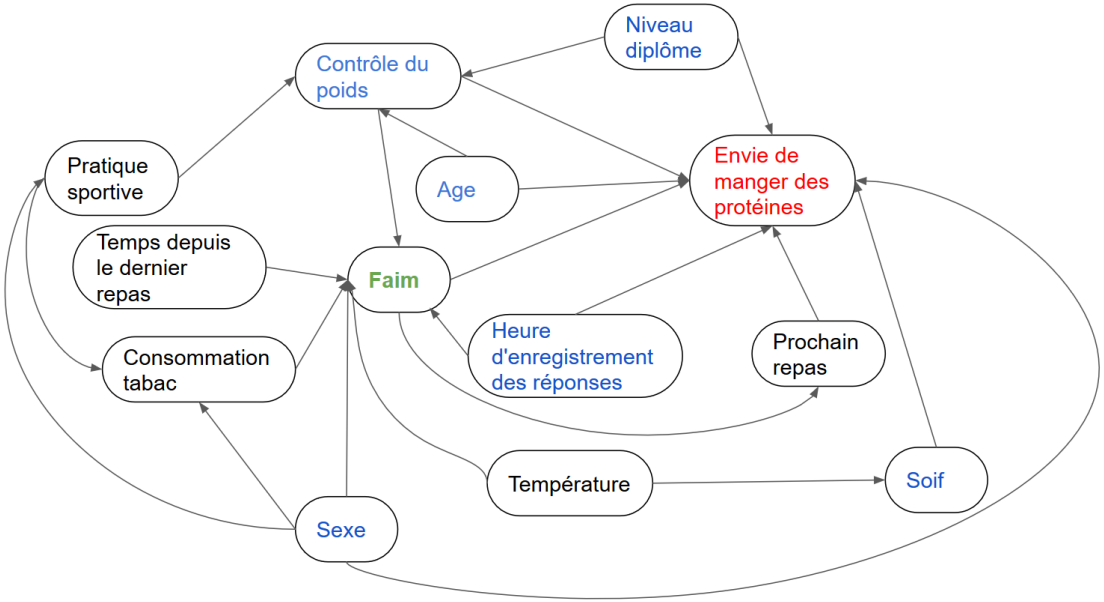

- Quelles **recommandations** faire à un consommateur pour qu'il baisse sa consommation d'aliments carnés ?

- Quel impact **si on double le prix** de … ?

- Quel rendement aurais-je eu l'année dernière **si j'avais** planté du ... au lieu de ...

Apprentissage par renforcement

L'apprentissage par renforcement

…

The learning data are

- A **sequence** of perceptions, actions and rewards $(s_t, a_t, r_t)_{t=1,\infty}$
  - With a **reinforcement** r_t
  - That can be related to past actions made far before t

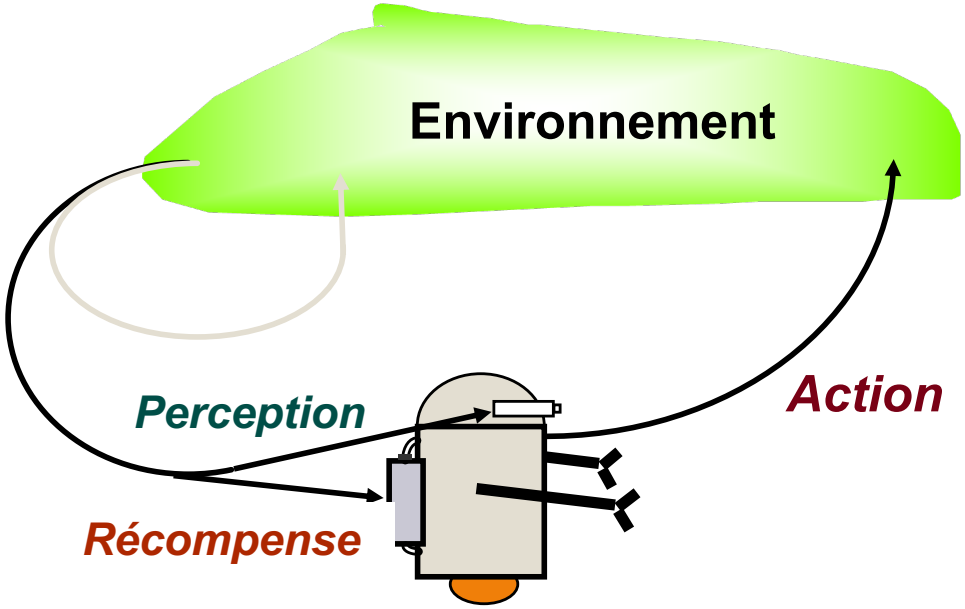

The problem: **infer a function**

perceived ***situation*** → ***action***

so as to maximise a gain over long term

$$R_t = r_{t+1} + \gamma\, r_{t+2} + \gamma^2\, r_{t+3} + \ldots + r_T = \sum_{k=0}^{\infty} \gamma^k\, r_{t+k+1}$$

Akin to **learning reflexes**

Les **grands types** d'apprentissage

- Apprentissage « par **renforcement** » (comment (ré)agir)

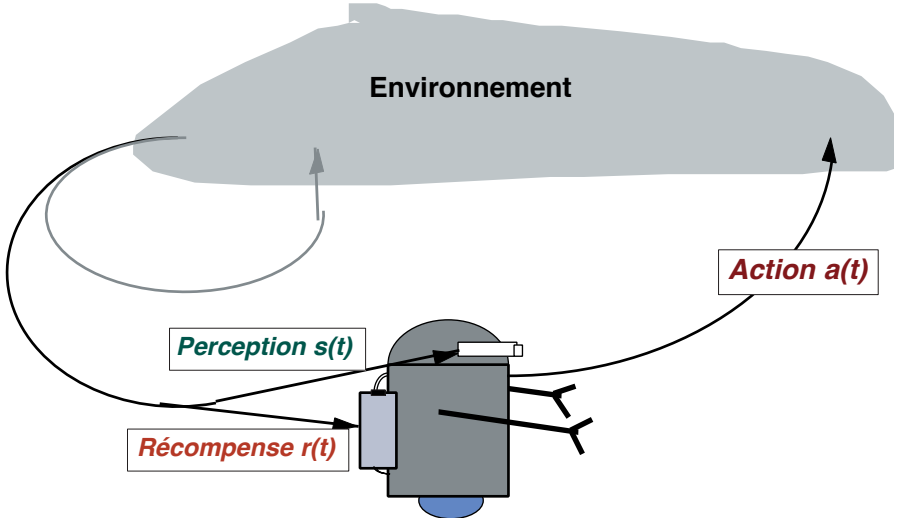

1. **Piloter** un hélicoptère
2. Apprendre à **jouer au tennis de table**
3. Battre le champion de **back-gammon** (1992), de **Go** (2016)
4. **Gérer un porte-feuille** d'investissements
5. **Contrôler une usine** de production électrique

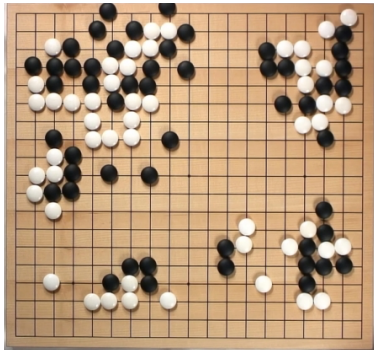

Illustration : Grand DARPA challenge (2005)

Illustration : Grand DARPA challenge (2005)

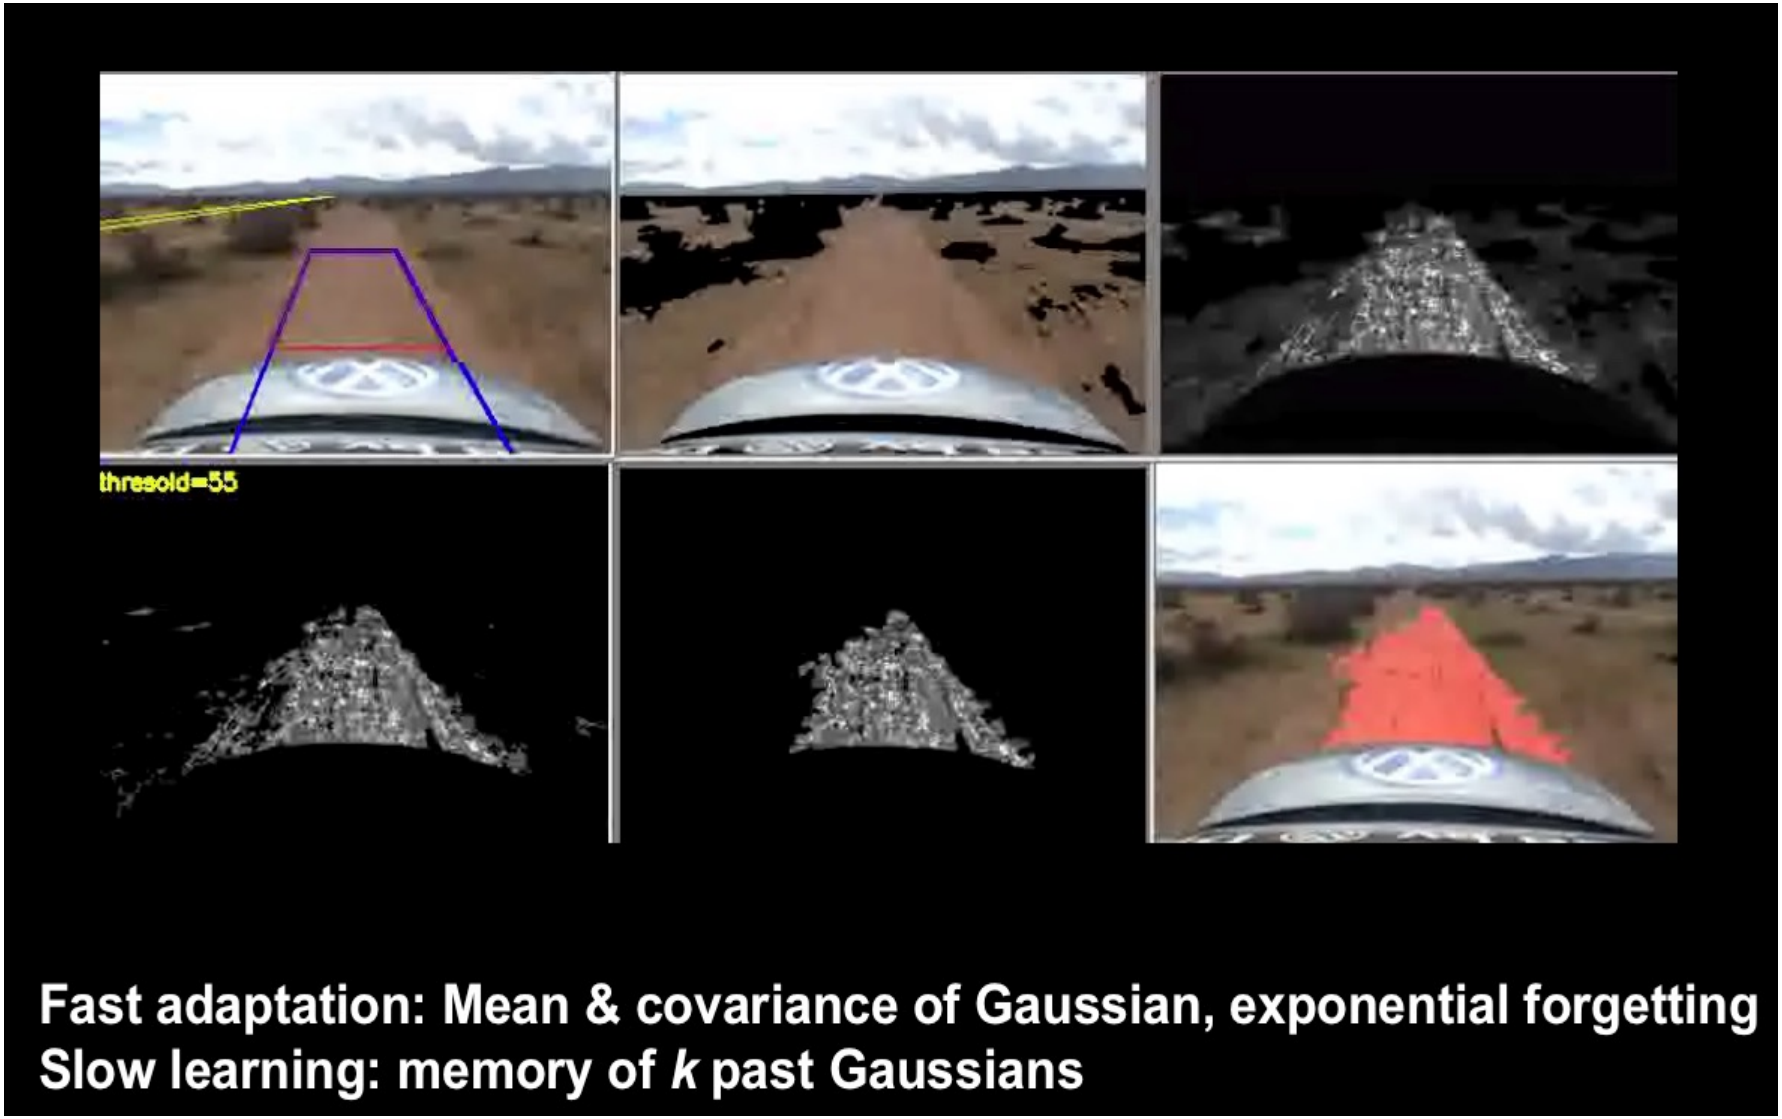

Autonomous vehicule

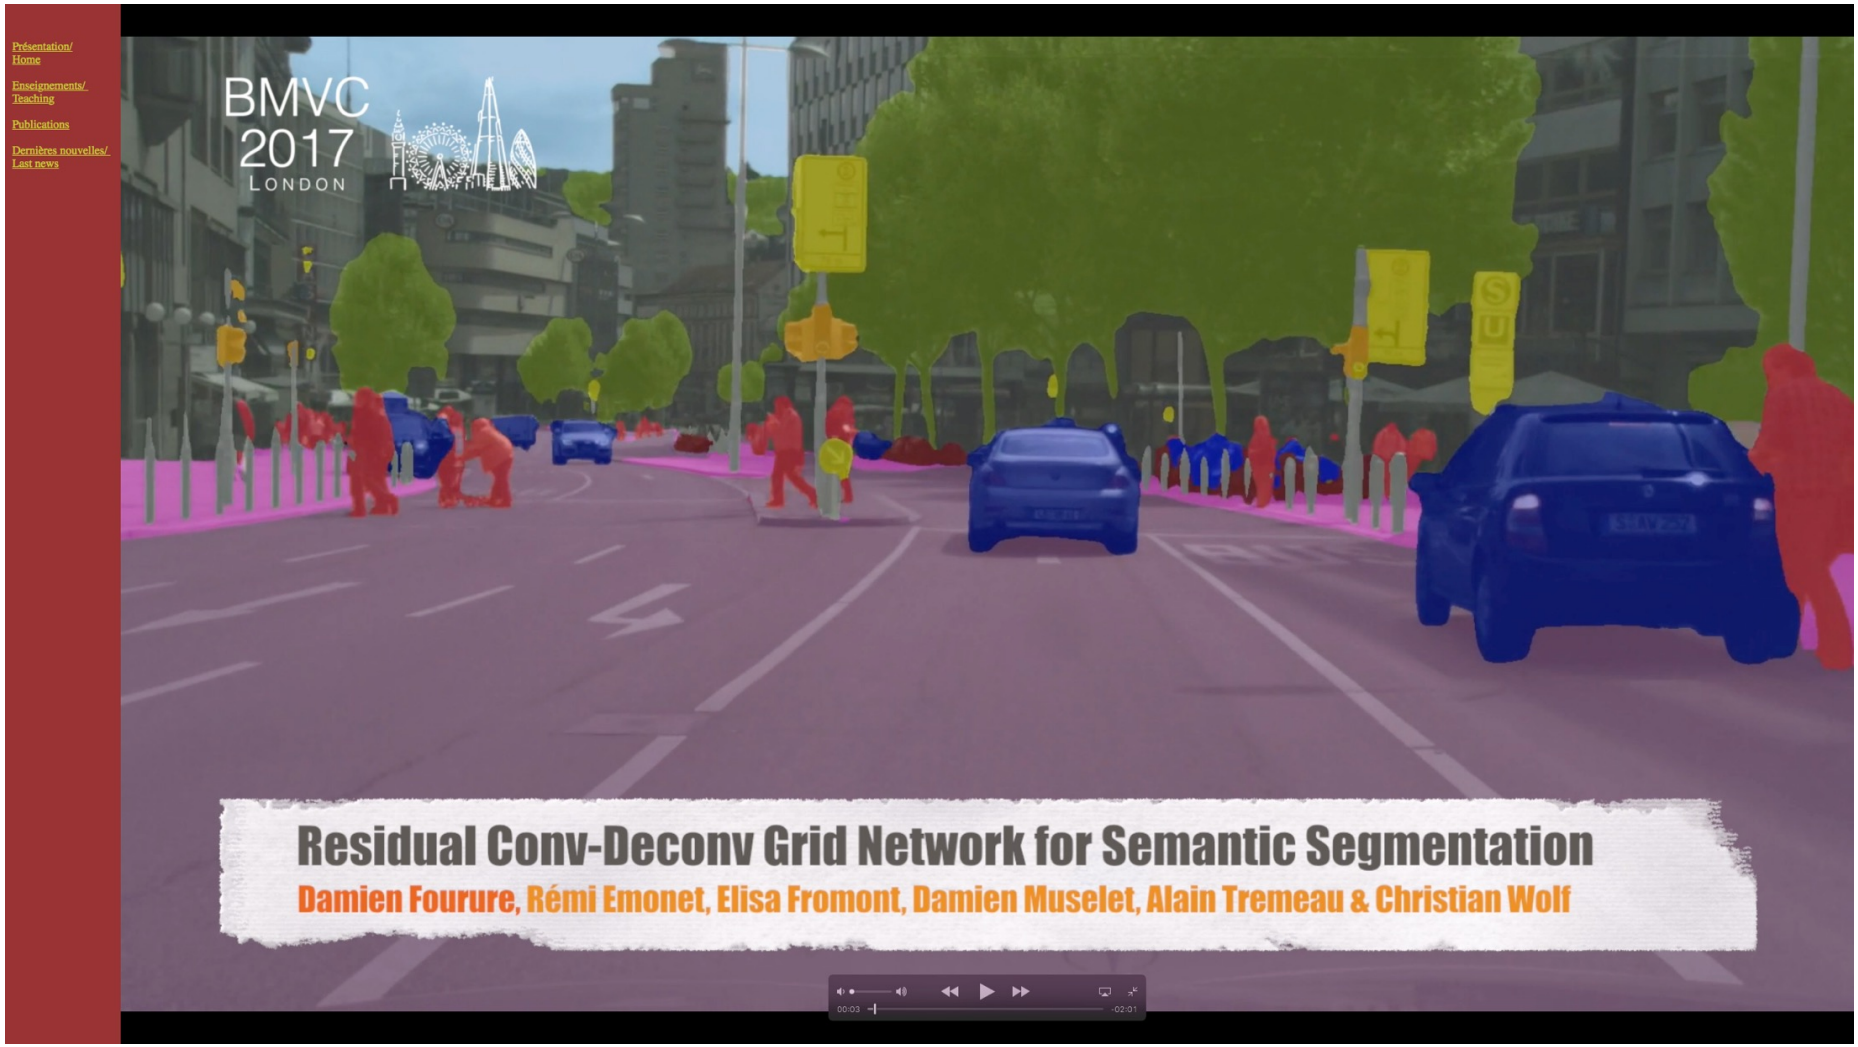

Results by Damien Fourure on the Cityscape dataset for BMVC 2017 (Gridnet)

C’est quoi des données ?

Les données : organisation et types

Identifieur	Genre	Age	Niveau études	Marié ?	Nb enfants	Revenu	Profession	A prospecter ?
I_21	M	43	Bac+5	Oui	3	55 000	Architecte	OUI
I_34	M	25	Bac+2	Non	0	21 000	Infirmier	NON
I_38	F	34	Bac+8	Oui	2	35 000	Chercheuse	OUI
I_39	F	67	Bac	Oui	5	20 000	Retraitée	NON
I_58	F	56	CAP	Oui	4	27 000	Ouvrière	NON
I_73	M	40	Bac+3	Non	2	31 000	Commercial	OUI
I_81	F	51	Bac+5	Oui	3	75 000	Chef d'entreprise	OUI

Les données : organisation et types

Identifieur	Genre	Age	Niveau études	Marié ?	Nb enfants	Revenu	Profession	A prospecter ?
I_21	M	43	Bac+5	Oui	3	55 000	Architecte	OUI
I_34	M	25	Bac+2	Non	0	21 000	Infirmier	NON
I_38	F	34	Bac+8	Oui	2	35 000	Chercheuse	OUI
I_39	F	67	Bac	Oui	5	20 000	Retraitée	NON
I_58	F	56	CAP	Oui	4	27 000	Ouvrière	NON
I_73	M	40	Bac+3	Non	2	31 000	Commercial	OUI
I_81	F	51	Bac+5	Oui	3	75 000	Chef d'entreprise	OUI

Exemple
(*example, instance*)

Descripteur
Attribut
(*feature*)

Étiquette
(*label*)

Les données

- **Vectorielles**
- Séquences
- Structurés
- Temporelles
- Spatiales

Identifieur	Genre	Age	Niveau études	Marié ?	Nb enfants	Revenu	Profession	A prospecter ?
I_21	M	43	Bac+5	Oui	3	55 000	Architecte	OUI
I_34	M	25	Bac+2	Non	0	21 000	Infirmier	NON
I_38	F	34	Bac+8	Oui	2	35 000	Chercheuse	OUI
I_39	F	67	Bac	Oui	5	20 000	Retraitée	NON
I_58	F	56	CAP	Oui	4	27 000	Ouvrière	NON
I_73	M	40	Bac+3	Non	2	31 000	Commercial	OUI
I_81	F	51	Bac+5	Oui	3	75 000	Chef d'entreprise	OUI

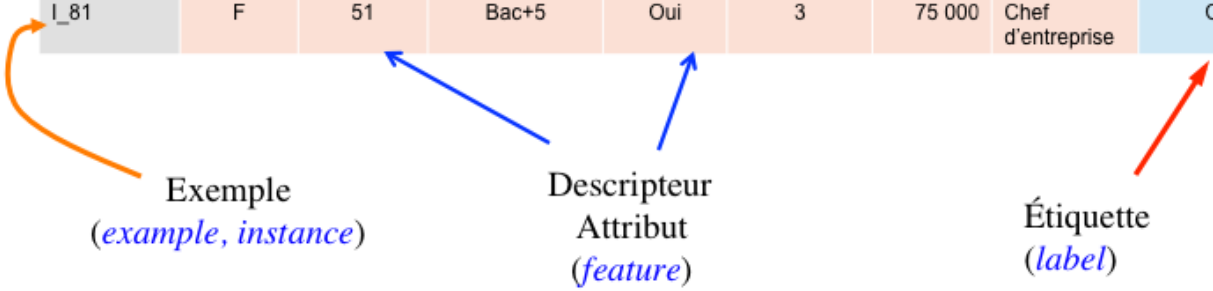

Induction supervisée

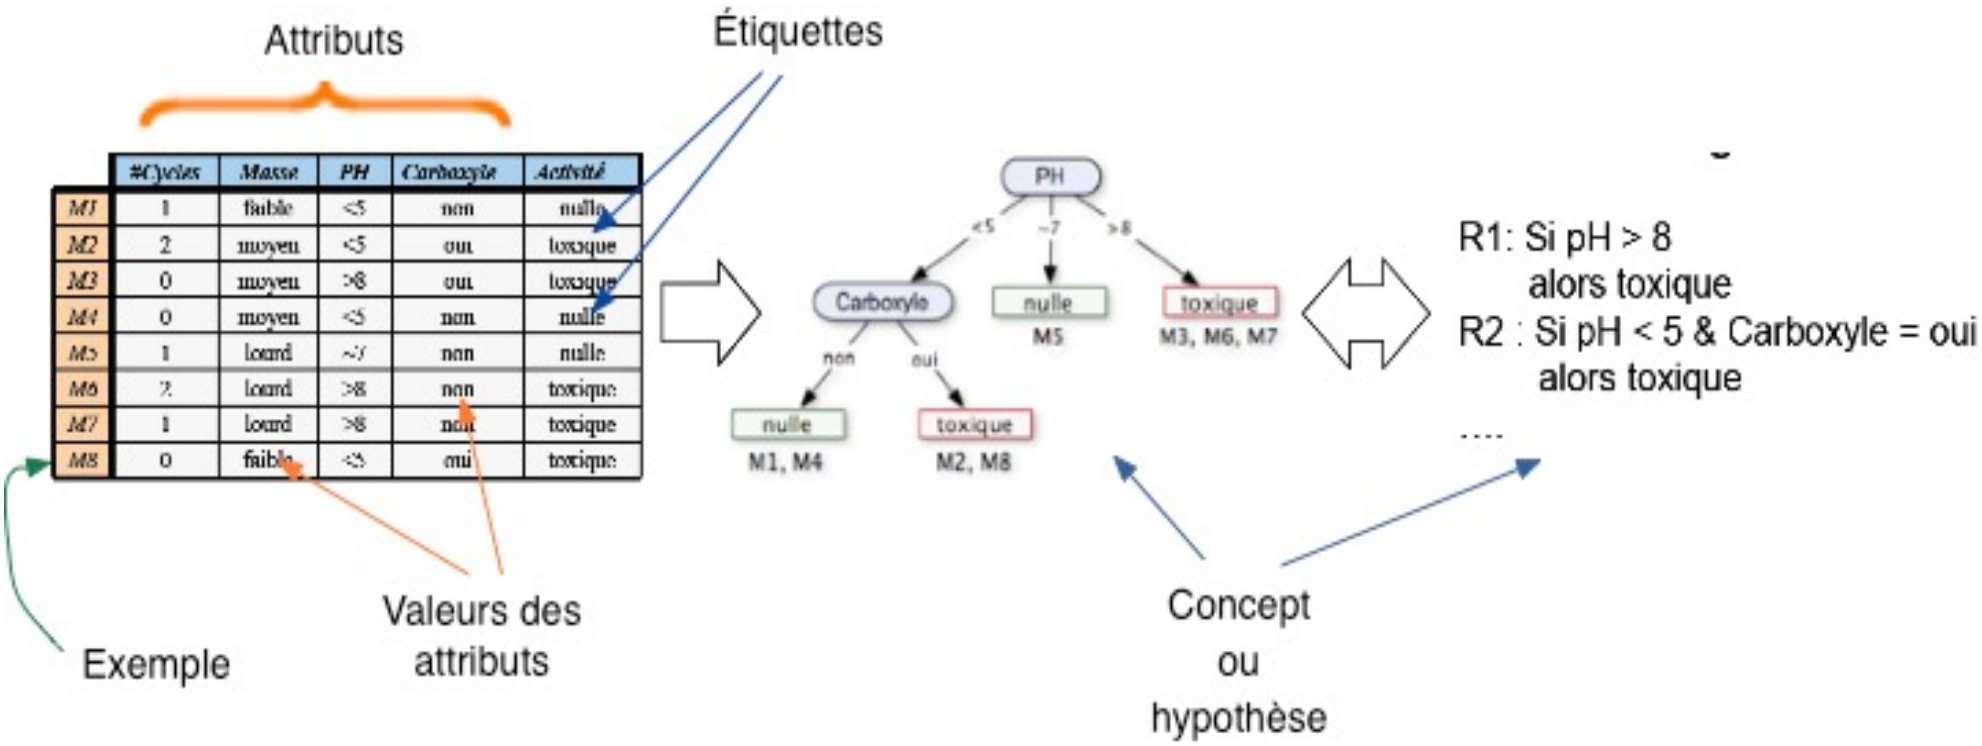

Les données

- Vectorielles
- **Séquences**
- Structurés
- Temporelles
- Spatiales

La protéine « sp|P00004|CYC_HORSE » est activée par …

```
 1   ttcagttgtg aatgaatgga cgtgccaaat agacgtgccg ccgccgctcg attcgcactt
61   tgctttcggt tttgccgtcg tttcacgcgt ttagttccgt tcggttcatt cccagttctt
121 aaataccgga cgtaaaaata cactctaacg gtcccgcgaa gaaaaagata aagacatctc
181 gtagaaatat taaaataaat tcctaaagtc gttggtttct cgttcacttt cgctgcctgc
 …
4021 agaacacgcc gaggctccat tcatagcacc acttcgtcgt cttaatcccc tccctcatcc
4081 gccatggcgg tgcaaaaaat aaaaagaact c
```

```
DEVICE=eth0
BOOTPROTO=none
ONBOOT=yes
IPADDR=192.168.0.X
NETMASK=255.255.255.O
GETEWAY=192.168.0.254
search exemple.com namserver
192.168.0.254
```

Les données

- Vectorielles
- Séquences
- **Structurés**
- Temporelles
- Spatiales

Logique du 1er ordre :

bloc(B1) & surtable(B2) & au-dessus(B1,B2) & …

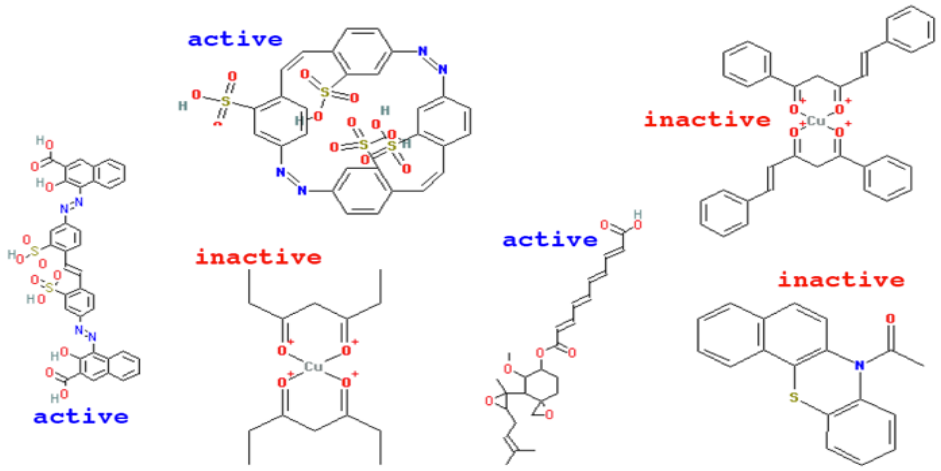

NCI AIDS screen results (from http://cactus.nci.nih.gov).

Les données

- Vectorielles
- Séquences
- Structurés
- **Temporelles**
- Spatiales

• **Apprentissage supervisé : interprétation d'IRMf**

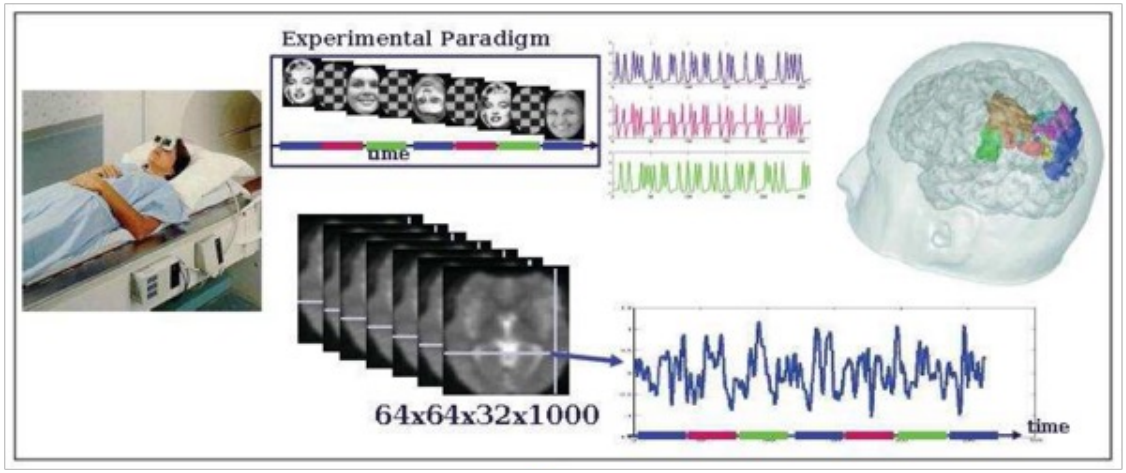

Trouble de la reconnaissance de visage ou *non*

Les données

- Vectorielles
- Séquences
- Structurés
- Temporelles
- **Spatiales**

Image MRS

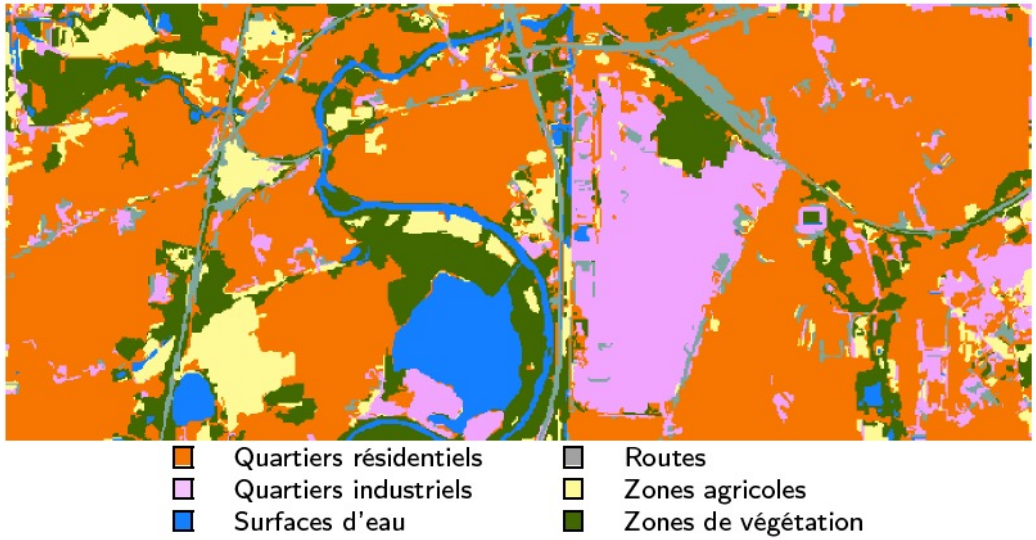

Types de formats

Numérique continue (R)	Compte en banque : 12 915,86 €
Numérique discrète (N ou Z)	Nombre d'enfants : 11
Binaire	Célibataire : vrai
Catégorie	Couleur dans {rouge, vert, bleu}
Texte	La protéine « sp|P00004|CYC_HORSE » est activée par …
Données structurées	Arbre, expression XML, … 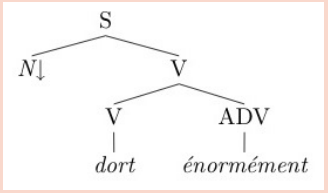 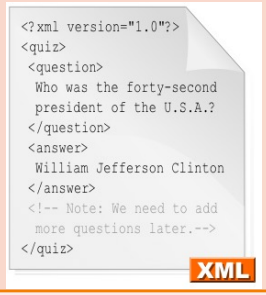
Séquences	- Génome - Séquence de requêtes sur site web
Images, vidéos	

Apprentissage supervisé

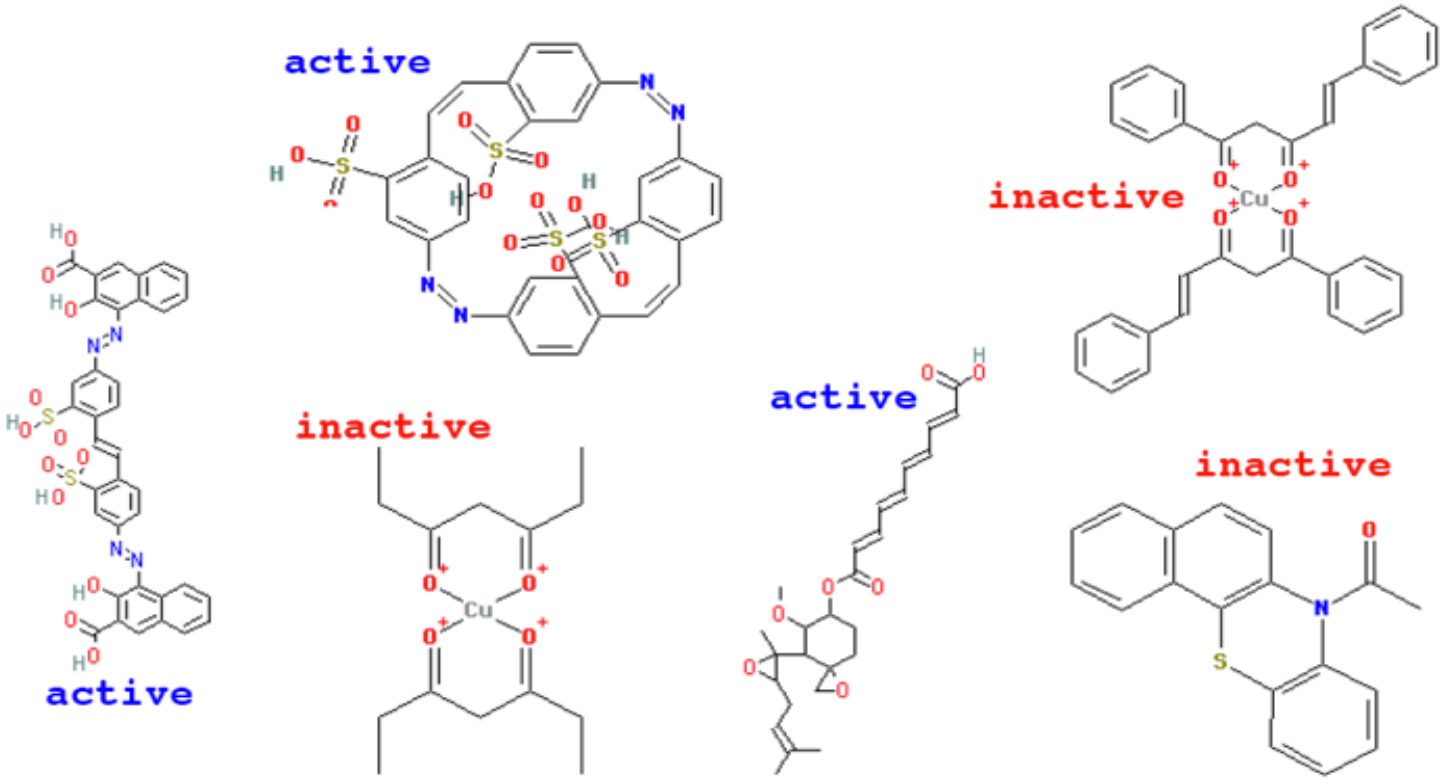

NCI AIDS screen results (from http://cactus.nci.nih.gov).

Plan

1. Une science de l'apprentissage ?
2. Les grands types d'apprentissage
3. Le problème de l'apprentissage supervisé
4. Apprendre dans un espace d'hypothèses structuré
5. Conclusion

Comment fonder l'induction ?